# Numerik WS 2021/22

## Ida Hönigmann

## April 8, 2024

## Contents

1	Gru	ındbegriffe	2	
	1.1	Gegenstand der Numerischen Mathematik	2	
	1.2	Kondition und Stabilität	2	
	1.3	Verfahrensfehler		
2	Interpolation			
	2.1	Lagrange-Polynominterpolation	4	
	2.2	Cebysev-Knoten	6	
	2.3	Lebesgue-Konstante		
	2.4	Auswertung von Interpolationspol		
	2.5	Hermite-Polynominterpolation		
	2.6	Spline-Interpolation		
	2.7	Diskrete und schnelle Fourier-Transformation		
3	Extrapolation 1'			
	3.1	Richardson-Extrapolation	17	
	3.2	Aitken'sches $\Delta^2$ -Verfahren		
4	Numerische Integration			
	4.1	Quadraturformeln	21	
	4.2	Interpolatorische Quadraturformeln		
	4.3	Gauss-Quadratur		
5	Iterative Lösung von GLS 27			
		Fixpunktprobleme	27	

## 1 Grundbegriffe

### 1.1 Gegenstand der Numerischen Mathematik

Von der Realität bis zur Interpretation einer Simulation ist es ein langer Weg.

- Mathematisches Modell versucht mit Hilfe von mathematischen Formeln (idR. Differentialgl.) die Realität zu beschreiben.
- Die wenigsten Lösungen dieser mathematischen Modelle kann man exakt berechnen, d.h. man approximiert die exakte Lösung mittels **numerischer Simulation** am Rechner.
- Diese numerische Lösung wird dann interpretiert und man hofft, dass diese Interpretation die Realität beschreibt.

Jede numerische Simulation zerfällt in kleinere **numerische Probleme**, die geeignet zu lösen sind. Die elementarsten numerischen Probleme sind Gegenstand dieser Vorlesung.

- **Beispiel 1.** Wie approximiert man komplizierte Funktionen mittels einfacher Funktionen (z.B. stückweise Polynome)?
  - Wie berechnet man Grenzwerte (z.B. Integral, Differential)?
  - Wie löst man lineare / nichtlineare Gleichungen?

Jede numerische Simulation ist fehlerbehaftet.

- Modellfehler: Das mathematische Modell vereinfacht die Realität.
- Datenfehler: Die Eingangsdaten einer Simulation stammen meistens aus physikalischen Messungen und haben daher eine gewisse Mess(un-)genauigkeit.
- Rundungsfehler: Auf Rechnern ersetzt die endliche Menge an Gleitkommazahlen das kontinuierliche  $\mathbb{R}$ , d.h. sowohl die Daten als auch die Rechnungen sind rundungsfehlerbehaftet.
- Verfahrensfehler: Viele Probleme werden mathematisch in unendlich dimensionalen Räumen oder mit Limiten formuliert. Beides steht im Rechner nicht zur Verfügung und muss diskretisiert werden.

In der Vorlesung liegt unser Hauptaugenmerk auf dem Verfahrensfehler und dem Aufwand zugehöriger Algorithmen.

#### 1.2 Kondition und Stabilität

Betrachte ein abstraktes Problem. Werte  $\Phi: X \to Y$  bei  $x \in X$  aus, wobei X, Y geeignete normierte Räume sind. Die **Kondition eines Problems** besagt, wie stark Änderungen in x (z.B. Rundungsfehler) sich auf  $\Phi(x)$  auswirken.

**Definition 1.** Das Problem ist **schlecht konditioniert bzgl. absolutem Fehler**, wenn es eine kleine Störung  $\tilde{x}$  von x gibt mit  $||\Phi(x) - \Phi(\tilde{x})|| \gg ||x - \tilde{x}||$ .

Das Problem ist schlecht konditioniert bzgl. relativem Fehler, falls  $x \neq 0 \neq \Phi(x)$  und es ex. eine kleine Störung  $\tilde{x}$  von x gibt mit  $\frac{||\Phi(x) - \Phi(\tilde{x})||}{||\Phi(x)||} \gg \frac{||x - \tilde{x}||}{||x||}$ .

Andernfalls bezeichnet man das Problem als gut konditioniert (bzgl. abs./rel. Fehler).

Bemerkung 1. Ist  $\Phi$  stetig differenzierbar, d.h.  $\Phi(x) - \Phi(\tilde{x}) = D\Phi(x)(x - \tilde{x}) + o(||x - \tilde{x}||)$  für  $\tilde{x} \to x$  so beschreibt die Ableitung  $D\Phi(x) \in L(X,Y)$  wie stark sich Änderungen in x auf den Fehler auswirken.

Deshalb bezeichnet  $man \, \kappa_{abs}(x) = ||D\Phi(x)||, \, \kappa_{rel}(x) = \frac{||D\Phi(x)|| \cdot ||x||}{||\Phi(x)||} \, als \, \textit{Konditionszahlen (bzgl. abs./rel. Fehler)}, \, d.h. \, man \, ist \, gut \, konditioniert \, für \, \kappa_{abs}, \kappa_{rel} \, vergleichsweise \, klein.$ 

**Definition 2.** Es sei  $\tilde{\Phi}$  eine algorithmische Umsetzung von  $\Phi$ . Der Algorithmus  $\tilde{\Phi}$  ist **instabil**, wenn es eine kleine Störung  $\tilde{x}$  von x gibt, sodass  $||\Phi(x) - \tilde{\Phi}(\tilde{x})|| \gg ||\Phi(x) - \Phi(\tilde{x})||$ .

tatsätlicher Fehler im Rechner unvermeidlicher Fehler

Andernfalls ist der Algorithmus stabil.

Bemerkung 2. Mir ist bewusst, dass die Symbolik » ("wesentlich größer") ungenauer ist, als Sie es aus anderen Vorlesungen kennen. Aber "schlecht konditioniert" und "instabil" hängt halt an der Genauigkeit der Daten und den Erfordernissen des Nutzers!

In der Vorlesung geht es primär um die Asymptotik, d.h. was könnte im Worst-Case passieren.

Erinnerung/Warnung: Die Arithmetik im Rechner erfüllt weder Assoziativität noch Distributivgesetz, d.h. die Reihenfolge (und Formulierung) der Rechenoperatoren spielt eine Rolle für Stabilität.

Beispiel 2 (schlechte Kondition bei Auslöschung). Als Auslöschung bezeichnet man das Phänomen, dass bei Subtraktion zweier annähernd gleicher Zahlen im Rechner die hinteren Ziffern (welche rundungsbehaftet sind) signifikant werden. Der relative Fehler kann sogar beliebig groß werden, d.h.  $\Phi: \mathbb{R}^2 \to \mathbb{R}, (x,y) \mapsto x-y$  hat  $\kappa_{rel}(x,y) = \frac{\sqrt{2}||(x,y)||_2}{|x-y||} \gg 0$  für  $x \approx y$ .

Achtung: Oft ist ein Problem gut konditioniert, wird aber in Teilprobleme zerlegt (im Algorithmus) sodass der resultierende Algorithmus instabil wird.

Beispiel 3. Werte  $\Phi(x) = \frac{1}{x+1} - \frac{1}{x} \text{ für } x \gg 0 \text{ aus.}$ 

$$\Phi'(x) = -\frac{1}{(x+1)^2} + \frac{1}{x^2} = \frac{(x+1)^2 - x^2}{x^2(x+1)^2} = \frac{2x+1}{x^2(x+1)^2}$$

$$\Phi(x) = \frac{x - (x+1)}{x(x+1)} = \frac{-1}{x(x+1)}$$

$$\kappa_{rel}(x) = \frac{|\Phi'(x)| \cdot |x|}{|\Phi(x)|} = \frac{(2x+1)}{x^2(x+1)^2} x^2(x+1) = 1 + \frac{x}{x+1} \le 2$$

 $\implies$  gut konditioniert!

**Beispiel 4.** Es sei ||.|| eine Norm auf  $\mathbb{K}^n$  und wir verwenden dieselbe Notation für die induzierte Operatornorm  $||A|| := \sum_{x \in \mathbb{K}^n, x \neq 0} \frac{||Ax||}{||x||}$  für  $A \in \mathbb{K}^{n \times n}$ .

Ist A invertierbar, so bezeichnet  $cond(A) := ||A|| \cdot ||A^{-1}||$  die Konditionszahl von A (bzgl. ||.||). Betrachtet man das Lösungsproblem  $\Phi : \mathbb{K}^n \to \mathbb{K}^n$ ,  $\Phi(b) = A^{-1}b$ , so gilt für die relative Konditionszahl (mit  $x = A^{-1}b$ )

$$\kappa_{rel}(b) = \frac{||D\Phi(b)|| \cdot ||b||}{||\Phi(b)||} = \frac{||A^{-1}|| \cdot ||Ax||}{||x||} \le cond(A),$$

wobei die letzte Abschätzung scharf ist, d.h. es gilt Gleichheit für mindestens ein b (und ein x).

#### 1.3 Verfahrensfehler

Im Wesentlichen gibt es zwei Arten von Verfahrensfehlern

- Abbruchfehler, wenn ein konvergenter (aber unendlicher) Algorithmus nach endlich vielen Schritten abgebrochen wird.
- **Diskretisierungsfehler**, wenn eine kontinuierliche Größe durch eine diskrete vereinfacht wird, z.B. Differenzenquotienten statt Differenzialquotient.

**Beispiel 5** (Abbruchfehler Heron-Verfahren). Für x > 0 def.  $y_1 := \frac{1}{2}(1+x), y_{n+1} := \frac{1}{2}(y_n + \frac{x}{y_n}).$ 

$$\implies y_{n+1}^2 - x = \frac{1}{4}(y_n^2 + 2x + \frac{x^2}{y_n}) - x = \frac{1}{4}(y_n - \frac{x}{y_n})^2 \ge 0$$

$$\implies y_{n+1}^2 \ge x > 0 \text{ und } y_{n+1} - y_n = \frac{1}{2}(y_n + \frac{x}{y_n}) - y_n = \frac{x}{2y_n} - \frac{y_n}{2} = \frac{x - y_n^2}{2y_n} \le 0$$

$$\implies 0 < \sqrt{x} \le y_{n+1} \le y_n \implies y_n \to y$$

$$\implies y = \frac{1}{2}(y + \frac{x}{y}) \implies \frac{1}{2}y^2 = \frac{1}{2}y^2 + \frac{1}{2}x \implies y^2 = x \implies y = \sqrt{x}$$

 $\implies (y_n)$  konvergiert monoton fallend gegen  $\sqrt{x}$ . Sobald  $y_n = \sqrt{x}$ , würde auch  $y_{n+1} = \sqrt{x}$  gelten, d.h. endkonstante Folge.

**Später**: Heron-Verfahren ist tatsächlich **quadratisch konvergent**, d.h. ex. C > 0 mit  $|\sqrt{x} - y_{n+1}| \le C|\sqrt{x} - y_n|^2$ .  $\implies$  schnelle konvergenz, weil sich korrekte Ziffern pro Schritt verdoppeln!

**Beispiel 6** (Diskretesierungsfehler einseitiger Differenzenquotient). Sei  $f: \mathbb{R} \to \mathbb{R}$  differenzierbar,  $x \in \mathbb{R}$ 

Ziel: Approximiere  $\Phi := f'(x)$  durch den einseitigen Diffquot.  $\Phi_h = \frac{f(x+h) - f(x)}{h}$ 

klar:  $\Phi_h \to \Phi$  für  $h \to 0$ , aber die Konvergenz kann beliebig langsam sein. Man interessiert sich in der Numerik auch für Konvergenzraten bzgl. des Diskretisierungsparameters.

 $F\ddot{u}r \ f \in C^2$  (lokal um x) gilt nach Mittelwertsatz

$$f'(x) - \frac{f(x+h) - f(x)}{h} = f'(x) - f'(\zeta) = f''(\xi)(x-\zeta)$$

 $mit\ Zwischenstellen\ x \le \xi \le \zeta \le x+h$ 

$$\implies |\Phi - \Phi_n| \le ||f''||_{L^{\infty}(x,x+h)}h = \mathcal{O}(h)$$

d.h. hier Konvergenzrate 1 in h.

**Definition 3.** Es sei  $\Phi$  eine kontinuierliche Große mit Diskretisierung  $\Phi_h$  für h > 0. Dann bezeichnet man eine Abschätzung der Form  $|\Phi - \Phi_h| = \mathcal{O}(h^{\alpha})$  als **a-priori Fehlerabschätzung** mit Konvergenzrate  $\alpha > 0$  (auch Konvergenzordung).

Natürlich interessiert sich die Numerik für Verfahren, bei denen  $\alpha > 0$  möglich groß ist.

Beispiel 7 (zentraler Differenzenquotient).  $f: \mathbb{R} \to \mathbb{R}$  diffbar,  $x \in \mathbb{R}$ ,  $\Phi := f'(x)$  und  $\Phi_h := \frac{1}{2} \left( \frac{f(x+h) - f(x)}{h} + \frac{f(x) - f(x-h)}{h} \right)$ 

klar:  $\Phi_h \to \Phi$  für  $h \to 0$ ,  $|\Phi - \Phi_h| = \mathcal{O}(h)$  sofern  $f \in \mathcal{C}^2$  (lokal um x).

Für  $f \in \mathcal{C}^3$  (lokal um x) gilt mit Taylor f(x+h) = f(x)) +  $hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{6}f'''(\zeta)$  für geeignete  $x-h \leq \zeta_- \leq x \leq \zeta_+ \leq x+h$ 

$$\implies \frac{f(x+h) - f(x)}{h} = f'(x) + \frac{h}{2}f'(x) + \frac{h^2}{6}f'''(\zeta_{-})$$

$$\frac{f(x) - f(x-h)}{h} = f'(x) - \frac{h}{2}f'(x) + \frac{h^2}{6}f'''(\zeta_{+})$$

$$\implies |\Phi - \Phi_h| = \frac{h^2}{6}\frac{|f'''(\zeta_{+}) + f'''(\zeta_{-})|}{2} = \mathcal{O}(h^2)$$

d.h. Konvergenzrate  $\alpha = 2$ .

⇒ höhere Genauigkeit für gleiches h bzw. gleiche Genauigkeit für größeres h.

**Bemerkung 3.** Auslöschung tritt immer auf (insb. bei Diffquot.), aber sie wird abgemildert durch Verfahren höherer Ordnung. Eine andere Möglichkeit für Verfahren höherer Ordnung zur Approximation von f'(x) ist die Verwendung von Polynomapproximation, d.h.  $f \approx p$  Polynom und berechne  $p'(x) \approx f'(x)$ .

## 2 Interpolation

Bei einem Interpolationsproblem sind im einfachsten Fall Paare  $(x_j, y_j)$  gegeben und eine "einfache" Funktion p mit  $p(x_j) = y_j \forall j$  gesucht, z.B. Polynome, Splines (= stückweise Polynome), rationale Funktionen (= Quotienten von Polynomen). Verwandt, aber mathematisch schwieriger sind Approximationsprobleme. Dabei ist eine Funktion f und eine Norm ||.|| gegeben, und es wird eine einfache Funktion p gesucht, die ||f-p|| in dieser Klasse einfacher Fkt. minimiert. Oft ist dabei die Funktion f nur implizit gegeben, d.h. unbekannt.

#### 2.1 Lagrange-Polynominterpolation

**Problemstellung:** Gegeben sind n+1 reelle **Stützstellen**  $a \le x_0 < ... < x_n \le b$  und **Funktionswerte**  $y_0,...,y_n \in \mathbb{K}$ . Die **Lagrange-Interpolationsaufgabe** sucht ein Polynom  $p \in \mathbb{P}_n = \{p(x) = \sum_{j=0}^n a_j x^j | a_0,...,a_n \in \mathbb{K}\}$  vom Grad n mit  $p(x_j) = y_j \forall j = 0,...,n$ 

**Lemma 1.** 1.  $\mathbb{P}_n$  ist  $\mathbb{K}$ -Vektorraum mit dim  $\mathbb{P}_n = n + 1$ .

- 2. Die Monome  $p_i(x) = x^j, j = 0, ..., n$  sind eine Basis von  $\mathbb{P}_n$ .
- 3. Die Lagrange-Polynome  $L_j(x) = \prod_{k=0, k \neq j}^n \frac{x-x_k}{x_j-x_k} \in \mathbb{P}_n$  erfüllen  $L_j(x_k) = \delta_{jk}$  für alle j, k = 0, ..., n und bilden eine Basis von  $\mathbb{P}_n$ .
- 4. Die Newton-Polynome  $q_j(x) = \prod_{k=0}^{j-1} (x x_k) \in \mathbb{P}_j$  für j = 0, ..., n bilden eine Basis von  $\mathbb{P}_n$ .

*Proof.* klar:  $\mathbb{P}_n$  ist  $\mathbb{K}$ -Vektorraum, dim  $\mathbb{P}_n \leq n+1$ , zz:  $\{L_0, ..., L_n\} \subseteq \mathbb{P}_n$  lin. unab. Sei  $\mu_0, ..., \mu_n \in \mathbb{K}$  mit  $\sum_{j=0}^n \mu_j L_j(x) = 0 \forall x$ Für  $x = x_k$  folgt

$$0 = \sum_{j=0}^{n} \mu_j \underbrace{L_j(x_k)}_{=\delta_{jk}} = \mu_k$$

 $\implies$  lin. unab. laut Def.  $\implies$  dim  $\mathbb{P}_n \ge n+1 \implies$  Monome + Lagrange Pol. bilden Basis von  $\mathbb{P}_n$ . zz.  $\{q_0, ..., q_n\} \subseteq \mathbb{P}_n$  lin. unab.

Seien 
$$\mu_0, ..., \mu_n \in \mathbb{K}$$
 mit  $\sum_{j=0}^n \mu_j \underbrace{q_j(x)}_{=\prod_{j=1}^{j-1} (x-x_k)} = 0.$ 

Seien 
$$\mu_0, ..., \mu_n \in \mathbb{K}$$
 mit  $\sum_{j=0}^n \mu_j \quad q_j(x) = 0$ .

$$= \prod_{k=0}^{j-1} (x-x_k)$$
Für  $x = x_0$  folgt  $\mu_0 q_0(x) = 0 \implies \mu_0 = 0$ .

Für  $x = x_1$  folgt  $\mu_1 \underbrace{q_1(x)}_{\neq 0} = 0$ , also  $\mu_1 = 0$ . Induktives Vorgehen zeigt  $\mu_j = 0 \forall j$ .

Satz 1 (Eindeutigkeit + Existenz). Betrachte Lagrange-Interpolation zu Stützstellen  $a \le x_0 < ... < x_n \le b$  und Funktionswerten  $y_0,...,y_n \in \mathbb{K}$ . Dann existiert ein eindeutiges  $p \in \mathbb{P}_n$  mit  $p(x_j) = y_j \forall j$ . Dieses wird gegeben durch  $p = \sum_{j=0}^n y_j L_j$ . Ist  $\{q_0,...,q_n\} \subseteq \mathbb{P}_n$  eine Basis von  $\mathbb{P}_n$  und  $p = \sum_{j=0}^n \lambda_j q_j$ , so löst  $\lambda = (\lambda_0,...,\lambda_n)$  das lineare Gleichungssystem

$$\underbrace{\begin{pmatrix} q_0(x_0) & \dots & q_n(x_0) \\ \vdots & & \vdots \\ q_0(x_n) & \dots & q_n(x_n) \end{pmatrix}}_{=: A} \lambda = \begin{pmatrix} y_0 \\ \vdots \\ y_n \end{pmatrix}$$

Die Matrix A ist regulär, d.h.  $\lambda$  ist die eindeutige Lösung.

*Proof.* Da  $L_j(x_k) = \delta_{jk} \forall j, k$  ist offensichtlich, dass  $p = \sum_{j=0}^n \mu_j L_j$  genau dann das Interpolationsproblem löst, wenn  $\mu_j = y_j \forall j$ .  $\Longrightarrow$  Eindeutigkeit + Existenz

Def. Lösungsoperator  $\mathcal{P}: \mathbb{K}^{n-1} \to \mathbb{P}_n$  durch  $(\mathcal{P}y)(x_j) = y_j \forall j = 0, ..., n \forall y \in \mathbb{K}^{n+1}$ 

 $\implies$  wohldef, bijektiv

Def. Auswertungsoperator  $\mathcal{A}: \mathbb{P}_n \to \mathbb{K}^{n+1}, p \mapsto (p(x_0), ..., p(x_n))$ 

 $\implies$  wohldef, linear

 $\mathcal{P} \circ \mathcal{A} = \text{Identität}, \, \mathcal{A} \circ \mathcal{P} = \text{Identität},$ 

 $\implies \mathcal{A} = \mathcal{P}^{-1}, \mathcal{P} = \mathcal{A}^{-1}$ 

 $\implies$  A ist die darstellende Matrix  $\mathcal{A}.\implies$  A ist regulär, da  $\mathcal{A}$  bijektiv, linear.

Bemerkung 4. Die Konditionszahl cond(A) der sogenannten Vandermonde-Matrix A hängt stark von der Wahl der Basis ab. Für die Lagrange-Polynome wäre A die Identität. Für die Monome ist cond(A) in der Regel indiskutabel schlecht (hängt an der Wahl der  $x_i$ ). Die Basiswahl beeinflusst auch die Besetzungsstruktur der Matrix.

Beispiel 8. Die Newton-Basis führt auf eine untere Dreiecksmatrix

$$\begin{pmatrix} 1 & 0 & \dots & 0 \\ 1 & q_1(x_1) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & q_1(x_n) & \dots & q_n(x_n) \end{pmatrix}$$

d.h. das lineare GLS kann in  $\mathcal{O}(n^2)$  statt  $\mathcal{O}(n^3)$  gelöst werden.

d.h. das lineare GLS kann in 
$$\mathcal{O}(n^2)$$
 statt  $\mathcal{O}(n^3)$  gelöst werder Lemma 2 (Horner-Schema). Sei  $p(x) = \sum_{j=0}^{n} \lambda_j \underbrace{q_j(x)}_{\prod_{k=0}^{j-1} (x-x_k)}$  Für einen Auswertungspunkt  $x \in \mathbb{R}$  betrachte

Für einen Auswertungspunkt  $x \in \mathbb{R}$  betrachte

- $y = \lambda_n$
- $for k = n 1 : -1_0$
- $y = (x x_k)y + \lambda_k$

- end
- $\implies$  Der Algorithmus berechnet in 3n Operationen den Funktionswert y = p(x).

**Satz 2** (Interpolationsfehlerdarstellung). Sei  $f \in C^{n+1}[a,b], 0 \le m \le n, p \in \mathbb{P}_n$  mit  $p(x_j) = f(x_j) \forall j = 0,...,n$ , wobei  $a \le x_0 < ... < x_n \le b$ 

$$\implies f^{(m)}(x) - p^{(m)}(x) = \frac{f^{(n+1)(\xi)}}{(n+1-m)!} \prod_{l=0}^{n-m} (x - \zeta_l),$$

wobei  $\xi = \xi(m, x)$  und  $\zeta_l = \zeta_l(m, x, x_0, ..., x_n)$  in [a, b] $F\ddot{u}r \ m = 0 \ gilt \ \zeta_l = x_l \forall l.$ 

Proof.  $e := f - p \in \mathcal{C}^{n+1}[a, b]$ 

 $\implies$  e hat mindestens n+1 Nullstenen (bei  $x_l$ )  $\implies$  e' hat mindestens n Nullstellen  $\implies$   $e^{(m)}$  hat mindestens n+1-m Nullstellen  $a < \zeta_0 < ... < \zeta_{n-m} < b$ 

o.B.d.A. 
$$x \notin \{\zeta_0, ..., \zeta_{n-m}\}$$

Def. 
$$F(y) := e^{(m)}(x)w(y) - e^{(m)}(y)w(x)$$
 mit  $w(x) := \prod_{l=0}^{m-n} (y - \zeta_l)$ 

$$\implies$$
  $F$  hat  $n+2-m$  Nullstellen  $\implies$   $F^{(n+1-m)}$  hat mind. 1 Nullstelle  $\xi$ 

$$0 = F^{(n+1-m)(\xi)} = \underbrace{e^{(m)}(x)}_{=f^{(m)}(x)-p^{(m)}(x)} \underbrace{w^{(n+1-m)}(\xi)}_{=(n+1-m)!} - \underbrace{e^{(n+1)}(\xi)}_{=f^{n+1}(\xi)} \underbrace{w(x)}_{=\prod_{l=0}^{n-m}(x-\zeta_l)}$$

Korollar 1 (Interpolationsfehler-Abschätzung). Seien  $f \in \mathcal{C}^{n+1}[a,b]$  reell- oder komplexwertig,  $a \leq x_0 < ... <$  $x_n \leq b, p \in \mathbb{P}_n \text{ mit } p(x_j) = f(x_j) \forall j = 0, ..., n, 0 \leq m \leq n$ 

$$\implies ||f^{(m)} - p^{(m)}||_{L^{\infty}(a,b)} \le C_{\mathbb{K}} \frac{||f^{(n+1)}||_{L^{\infty}(a,b)}}{(n+1-m)!} (b-a)^{n+1-m}$$

 $mit \ C_{\mathbb{K}} = 1 \ f\"{u}r \ reelwertiges \ f, \ C_{\mathbb{K}} = 2 \ f\"{u}r \ komplexwertiges \ f.$ 

*Proof.* klar für  $\mathbb{K} = \mathbb{R}$ .

Für 
$$\mathbb{K} = \mathbb{C}$$
, betrachte  $Re(f), Im(f) \in \mathcal{C}^{n+1}[a, b]$ .

Bemerkung 5. Aus der Fehlerabschätzung und der Konvergenz der Exponentialreihe  $exp(y) = \sum_{k=0}^{\infty} \frac{y^k}{k!}$  folgt, dass der Interpolationsfehler "schnell" konvergiert, sofern sich die Ableitungen  $||f^{(k)}||_{L^{\infty}(a,b)}$  gut verhalten (z.B.  $||f^{(k)}||_{L^{\infty}(a,b)} \le M < \infty).$ 

Bemerkung 6. Für m = 1, a = x und b = x + h folgt

$$|f'(x) - p'(x)| \le ||f' - p'||_{L^{\infty}(x,x+h)} \le C_{\mathbb{K}} \frac{||f^{(n+1)}||_{L^{\infty}(x,x+h)}}{n!} h^n$$

d.h. besser als die Differenzquotienten aus Kapitel 1.

#### 2.2 Cebysev-Knoten

**Definition 4.** Sei  $f : \mathbb{R} \to \mathbb{R}$  eine Funktion und  $x \in \mathbb{R}$ . Man nennt x eine **n-fache Nullstelle von** f, gdw. f(x) = 0 und f is lokal um x (n-1)-mal diffbar mit  $f^{(k)}(x) = 0 \forall k = 1, ..., n-1$ . Wir schreiben  $n(f, x) \in \mathbb{N}_0$ für die Vielfachheit.

**Lemma 3.** Sei  $p \in \mathbb{P}_n$  mit Nullstellen  $x_1 < ... < x_k$  und  $N := \sum_{j=1}^n n(f, x_j) > n$ .

 $\implies p = 0$ , d.h. ein nicht-triviales Polynom vom Grad n hat  $\leq n$  Nullstellen, wobei diese mit Vielfachheit qezählt werden.

*Proof.* Induktion nach n.

Ind.anf.: n = 0, d.h. p ist konstant mit mind. einer Nullstelle  $\implies p = 0$ 

Ind.hyp: Die Aussage gelte für alle Polynome  $q \in \mathbb{P}_{n-1}$ .

$$p \in \mathbb{P}_n$$
 hat Nullstellen  $x_1 < ... < x_k$  und  $N = \sum_{i=1}^k n(p, x_i) > n$ 

 $p \in \mathbb{P}_n$  hat Nullstellen  $x_1 < ... < x_k$  und  $N = \sum_{j=1}^k n(p, x_j) > n$   $\implies p \in \mathbb{P}_{n-1}$  hat Nullstellen  $\zeta_1 < ... < \zeta_{k-1}$  mit  $x_j < \zeta_j < x_{j+1}$  (nach MWS) und bei allen  $x_j$  mit  $n(p, x_j) > 1.$ 

Für die Nullstellen von  $p' \in \mathbb{P}_{n-1}$  gilt also

$$\sum_{j=1}^{k-1} \underbrace{n(p', \zeta_j)}_{\geq 1} + \sum_{j=1}^{k} \max\{n(p, x_j) - 1, 0\} \geq -1 + \underbrace{\sum_{j=1}^{k} \underbrace{(\max\{n(p, x_j) - 1, 0\} + 1)}_{\geq n(p, x_j)}}_{=N > n} > n - 1$$

$$\implies p' = 0 \implies p \text{ konstant } \implies p = 0.$$

Bemerkung 7. Aus der linearen Algebra wissen wir, dass sich jedes Polynom  $p \in \mathbb{P}_n$  mit Nullstelle  $x_0$  in der Form  $p(x) = q(x)(x - x_0)$  schreiben lässt mit  $q \in \mathbb{P}_{n-1}$ , sog. **Polynomdivision**.

Ferner gilt der **Fundamentalsatz der Algebra**: Für jedes  $p \in \mathbb{P}_n$  existieren  $x_1, ..., x_n \in \mathbb{C}$  und  $\lambda \in \mathbb{C}$  mit  $p(x) = \lambda \prod_{i=1}^n (x - x_i)$ . Offensichtlich ist diese Aussage viel stärker als "mein Lemma".

**Ziel**: Für m = 0 gilt für alle  $x \in [a, b]$ 

$$|f(x) - p(x)| \le C_{\mathbb{K}} \frac{||f^{(n+1)}||_{L^{\infty}(a,b)}}{(n+1)!} \prod_{l=0}^{n} |x - x_{l}|,$$

wenn f glatt und  $p \in \mathbb{P}_n$  Lagrange-Interpolationspolynom zu  $x_j$ .

Nun wollen wir die  $x_j$  so wählen, dass  $\max_{x \in [a,b]} \prod_{l=0}^n |x - x_l|$  minimal wird.

**Definition 5.** Für  $n \in \mathbb{N}_0$  definiere die Cebysev-Polynome (der ersten Art) durch  $T_n(t) := \cos(n \arccos t)$  auf [-1, 1].

**Lemma 4.** 1.  $T_n(\cos(\Phi)) = \cos(n\Phi) \forall 0 \le \Phi \le \pi \forall n \in \mathbb{N}_0$ 

- 2. Auf[-1,1] gilt  $T_0(t) = 1$ ,  $T_1(t) = t$ ,  $T_{n+1}(t) = 2tT_n(t) T_{n-1}(t) \forall n \in \mathbb{N}$
- 3.  $T_n \in \mathbb{P}_n[-1,1]$  mit Leitkoeffizient  $2^{n-1}$  für  $n \ge 1$
- 4.  $||T_n||_{L^{\infty}(-1,1)} = 1$
- 5.  $T_n$  hat in [-1,1] genau n+1 lokale Extrema  $T_n(s_j^{(n)})=(-1)^j$  mit  $s_j^{(n)}=\cos\left(\frac{j\pi}{n}\right)$  für j=0,...,n
- 6.  $T_n$  hat in [-1,1] genau n einfache Nullstellen  $T_n(t_j^{(n)}) = 0$ ,  $t_j^{(n)} = \cos\left(\frac{(2j-1)}{n}\frac{\pi}{2}\right)$  für j = 1,...,n

nur die sog. Drei-Term-Rekursion in (2). Whl: Additionstheorem des Cosinus:  $\cos(x) + \cos(y) = 2\cos\left(\frac{x+y}{2}\right)\cos\left(\frac{x-y}{2}\right)$  $t = \cos(\Theta), x := (n+1)\Theta, y := (n-1)\Theta$ 

$$\Rightarrow \frac{x+y}{2} = n\Theta, \frac{x-y}{2} = \Theta$$

$$\Rightarrow T_{n+1}(t) + T_{n-1}(t) = \cos(\underbrace{(n+1)\Theta}_{x}) + \cos(\underbrace{(n-1)\Theta}_{y}) = 2\cos\left(\underbrace{\frac{x+y}{2}}_{n\Theta}\right)\cos\left(\underbrace{\frac{x-y}{2}}_{\Theta}\right)$$

Satz 3 (Optimalität der Cebysev-Knoten). Betrachte die affine Transformation  $\Psi: [-1,1] \to [a,b], \Psi(t) = \frac{1}{2}\{(a+b)+t(b-a)\}.$ 

Seien  $t_1^{(n+1)}, ..., t_{n+1}^{(n+1)}$  die Nullstellen von  $T_{n+1}$ .

$$\implies \min_{x_0, \dots, x_n \in [a, b]} \max_{x \in [a, b]} \prod_{j=0}^n |x - x_j| = \max_{x \in [a, b]} \prod_{j=0}^n |x - \Psi(t_{j+1}^{(n+1)})| = \left(\frac{b-a}{2}\right)^{n+1} \frac{1}{2^n}.$$

Die  $\Psi(t_{j+1}^{(n+1)})$  für j=0,...,n heißen Cebysev-Knoten in  $[{\pmb a},{\pmb b}].$ 

*Proof.* 1. zz: 
$$\max_{t \in [-1,1]} \prod_{i=0}^{n} |t - t_{i+1}^{(n+1)}| = \frac{1}{2^n}$$

Lemma (iii) + (vi) 
$$\implies T_{n+1}(t) = 2^n \prod_{j=0}^n (t - t_{j+1}^{(n+1)})$$

Lemma (iv) 
$$\implies 1 = ||T_{n+1}||_{L^{\infty}(-1,1)} = \max_{t \in [-1,1]} 2^n \prod_{i=0}^n |t - t_{i+1}^{(n+1)}|$$

2. zz.  $\frac{1}{2^n} \leq \inf_{t_0,...,t_n \in [-1,1]} \max_{t \in [-1,1]} \prod_{j=0}^n |t-t_j|$  (dann folgt die Behauptung für [a,b] = [-1,1]) Annahme: Ex.  $t_0,...,t_n \in [-1,1]$  mit  $w(t) := \prod_{j=0}^n (t-t_i)$  erfüllt

$$||w||_{L^{\infty}(-1,1)} = \max_{t \in [-1,1]} \prod_{j=0}^{n} |t - t_j| \leq \frac{1}{2^n}.$$

Definiere 
$$p := \underbrace{\frac{1}{2^n} T_{n+1}}_{\in \mathbb{P}_{n+1}} - \underbrace{w}_{\in \mathbb{P}_{n+1}} \in \mathbb{P}_n$$
. Ferner  $\frac{1}{2^n} T_{n+1}(s_j^{(n+1)}) = \frac{(-1)^j}{2^n}$  und  $|w(s_j^{n+1})| < \frac{1}{2^n}$ .

 $\implies p$  hat n+1 Vorzeichenwechsel  $\implies n+1$  Nullstellen  $\implies p=0 \implies w=\frac{1}{2^n}T_{n+1}$ 

3. klar:  $\Psi$  ist Bijektion von [-1,1] auf [a,b]  $\Psi(t) - \Psi(t_{i+1}^{(n+1)}) = \frac{1}{2}\{(t-t_{i+1}^{(n+1)})(b-a)\}$ 

$$\implies \max_{x \in [a,b]} \prod_{j=0}^{n} |x - \Psi(t_{j+1}^{(n+1)})| = \max_{t \in [-1,1]} \prod_{j=0}^{n} |\Psi(t) - \Psi(t_{j+1}^{(n+1)})| = \left(\frac{b-a}{2}\right)^{n+1} \underbrace{\max_{t \in [-1,1]} \prod_{j=0}^{n} |t - t_{j+1}(n+1)|}_{=\frac{1}{2n}}$$

2.3 Lebesgue-Konstante

**Satz 4.** Seien  $a \le x_0 < ... < x_n \le b$  Stützstellen mit zugehörigen Lagrange-Polynomen  $L_0, ..., L_n \in \mathbb{P}_n$ . Def.  $I_n : \mathcal{C}[a,b] \to \mathbb{P}_n, I_n f := \sum_{j=0}^n f(x_j) L_j$ .

 $\implies I_n$  ist eine lineare Projektion auf  $\mathbb{P}_n$  mit Operatornorm

$$||I_n|| := \sup_{f \in \mathcal{C}[a,b], f \neq 0} \frac{||I_n f||_{L^{\infty}(a,b)}}{||f||_{L^{\infty}(a,b)}} = \max_{x \in [a,b]} \sum_{j=0}^{n} |L_j(x)| =: \Lambda(x_0, ..., x_n).$$

Die Zahl  $\Lambda(x_0,...,x_n)$  heißt **Lebesgue-Konstante**.

*Proof.*  $I_n$  wohldef., linear  $\checkmark$ 

Für  $p \in \mathbb{P}_n$  gilt  $I_n p = p$ , da Polynominterpolation eine eindeutige Lsg. hat.

Für  $f \in \mathcal{C}[a,b]$  mit  $f \neq 0$  gilt

$$\frac{||I_n f||_{L^{\infty}(a,b)}}{||f||_{L^{\infty}(a,b)}} = \max_{x \in [a,b]} \left| \sum_{j=0}^{n} \frac{f(x_j)}{||f||_{L^{\infty}(a,b)}} L_j(x) \right| \le \Lambda(x_0, ..., x_n).$$

Um Gleichheit zu zeigen, wähle  $x \in [a,b]$  mit  $\sum_{j=0}^{n} |L_j(x)| = \Lambda(x_0,...,x_n)$ . Wähle  $f \in \mathcal{C}[a,b]$  als Polygonzug mit  $||f||_{L^{\infty}(a,b)} \leq 1$  und  $f(x_j) = signL_j(x)$ .  $\Longrightarrow$  Gleichheit bei obiger Abschätzung.

Bemerkung 8. Derselbe Beweis zeigt für  $\tilde{I}_n : \mathbb{K}^{n+1} \to \mathbb{P}_k, \tilde{I}_n(y_0,...,y_n) := \sum_{j=0}^n y_j L_j, \ dass \ ||\tilde{I}_n(y_0,...,y_n)||_{L^{\infty}(a,b)} \le \Lambda \max_{j=0,...,n} |y_j| \ mit \ Gleichheit für \ spezielle \ y_j = sign(L_j(x)), \ wenn \ x \in [a,b] \ mit \sum_{j=0}^n |L_j(x)| = \max_{\tilde{x} \in [a,b]} \sum_{j=0}^n |L_j(x)|.$   $\implies \tilde{I} \ ist \ der \ (lineare) \ L\"{o}sungsoperator \ der \ Pol.int.$ 

$$\implies ||\tilde{I}_n(y_0,...,y_n) - I_n(\tilde{y}_0,...,\tilde{y}_n)||_{L^{\infty}(a,b)} \le \Lambda \max_{j=0,...,n} |y_j - \tilde{y}_i|$$

d.h.  $\Lambda$  ist die abstrakte Konditionszahl der Polynominterpolation.

Abschließend einige Bemerkungen zum Bestapproximationsproblem.

**Lemma 5.** X normierter Raum,  $Y \le X$  endlich-dim. Teilraum,  $x \in X$   $\implies Ex. \ y \in Y \ mit \ ||x-y||_X = \min_{\tilde{y} \in Y} ||x-\tilde{y}||_X$ 

*Proof.* Wähle Folge  $(y_n)_{n\in\mathbb{N}}\subseteq Y$  mit

$$\lim_{n\to\infty}||x-y_n||_X=\inf_{\tilde{y}\in Y}||x-\tilde{y}||_X$$
 
$$\Longrightarrow ||y_n||_X\leq \underbrace{||x-y_n||_X}_{\text{glm. beschränkt wegen Konvergenz}}+||x||_X\implies \sup_{n\in\mathbb{N}}||y_n||_X\leq M<\infty$$

Da Y endl.-dim., gilt der Satz von Bolzano-Weierstraß, d.h.  $(y_n)_{n\in\mathbb{N}}$  hat eine konvergente Teilfolge. O.B.d.A. ex.  $y \in Y$  mit  $||y - y_n||_X \to 0$  für  $n \to \infty$ .

$$||x - y||_X = \lim_{n \to \infty} ||x - y_n||_X = \inf_{\tilde{y} \in Y} ||x - \tilde{y}||_X.$$

Bemerkung 9. Mit Satz über Lebesgue-Konstante und dem Lemma gilt für alle  $q \in \mathbb{P}_n$ 

$$\underbrace{\frac{||f - I_n f||_{L^{\infty}(a,b)}}{\geq \min_{q \in \mathbb{P}_n} ||f - q||_{L^{\infty}(a,b)}}} \leq ||f - q||_{L^{\infty}(a,b)} + \underbrace{\frac{||I_n (f - q)||_{L^{\infty}(a,b)}}{\leq \Lambda ||f - q||_{L^{\infty}(a,b)}}}$$

$$\implies \min_{q \in \mathbb{P}_n} ||f - q||_{L^{\infty}(a,b)} \leq ||f - I_n f||_{L^{\infty}(a,b)} \leq (1 + \Lambda) \min_{q \in \mathbb{P}_n} ||f - q||_{L^{\infty}(a,b)}$$

Bemerkung 10. Nach Satz von Weierstraß gilt  $\lim_{n\to\infty} \min_{p\in\mathbb{P}_n} ||f-p||_{L^{\infty}(a,b)} = 0 \forall f \in \mathcal{C}[a,b].$ 

Nach Satz von Faber gilt allerdings, dass es für jede Folge von Stützstellen  $(x_0^{(n)},...,x_n^{(n)})_{n\in\mathbb{N}}$  eine Funktion  $f\in\mathcal{C}[a,b]$  mit der Eigenschaft, dass  $||f-I_n^{(n)}f||_{L^{\infty}(a,b)}$  divergiert!

Insbesondere muss also  $\Lambda_n^{(n)} \to \infty$  gelten!

Bemerkung 11. Für äquidistante Stützstellen divergiert  $\Lambda_n$  exponentiell schnell. Für Cebysev-Knoten gilt allerdings  $\Lambda_n = \mathcal{O}(\log n)$ .

Bemerkung 12. Der Remez-Algorithmus berechnet (in unendlich vielen Schritten) ein Polynom  $q \in \mathbb{P}_n$  mit  $||f-q||_{L^{\infty}(a,b)} = \min_{p \in \mathbb{P}_n} ||f-p||_{L^{\infty}(a,b)} \forall f \in \mathcal{C}[a,b].$ 

Startwert ist dafür der Cebysev-Interpoland.

Der Alternantensatz von Cebysev zeigt, dass das Bestapprox.polynom  $q \in \mathbb{P}_n$  bzgl.  $||.||_{L^{\infty}(a,b)}$  in der Tat eindeutig ist.

#### 2.4 Auswertung von Interpolationspol.

**Satz 5** (Neville-Verfahren). Seien  $a \le x_0 < ... < x_n \le b$  Stützstellen mit Funktionswerten  $y_j \in \mathbb{K}$  und  $p \in \mathbb{P}_n$  mit  $p(x_j) = y_j \forall j = 0, ..., n, x \in [a, b]$  Auswertungspunkt.

 $F\ddot{u}r\ j, m \in \mathbb{N}_0 \ mit\ j+m \le n, \ definiere\ p_{j,m} \in \mathbb{P}_m \ als\ eind. \ Int.polynom\ mit\ p(x_k) = y_k \forall k=j,...,j+m$ 

$$p(x) = p_{0,n}(x)$$

$$p_{j,0}(x) = y_{j}$$

$$p_{j,m}(x) = \underbrace{\frac{(x - x_{j})p_{j+1,m-1}(x) - (x - x_{j+m})p_{j,m-1}}{x_{j+m} - x_{j}}}_{=:q(x),q \in \mathbb{P}_{m}}$$

Proof. 
$$q(x) = y_j, q(x_{j+m}) = y_{j+m}, q(x_k) = y_k, k = j+1, ..., n-m+1 \implies q = p_{j,m}$$

Dieser Satz führt auf das induktive Neville-Schema

Bemerkung 13. • Das Neville-Verfahren ist ein sog. Einschritt-Verfahren, d.h. eine "neue Spalte" nur mit Hilfe der vorausgegangenen Spalte berechnet.

• Wenn man "von oben nach unten rechnet", ist kein zusätzlicher Speicher nötig. In diesem Fall sollte man die "Diagonale" speichern.

• Man kann im Neville-Verfahren dann leicht einen neuen Punkt  $(x_{n+1}, y_{n+1})$  hinzunehmen und erhält  $p_{0,n+1}(x)$ , indem man nur die neue Diagonale rechnet.

**Algorithmus 1** (Neville). Input: Stützstellen  $a \le x_0 < ... < x_n \le b$ , Funktionswerte  $y_0, ..., y_n \in \mathbb{K}$ , Auswer $tungspunkt \ x \in \mathbb{R}$ 

- for m = 1 : n
- for j = 0 : n m
- $y_j = \frac{(x-x_j)y_{j+1} (x-x_{j+m})y_j}{x_{j+m} x_j}$
- *end*
- end

Output:  $y_0 = p(x)$ , wobei  $p \in \mathbb{P}_n$  mit  $p(x_j) = y_j \forall j$ klar: Speicherbedarf n+1 (überschreiben von y-Vektor), Arithmetischer Aufwand  $\frac{7}{2}n(n+1)$ .

**Definition 6.** Sei  $p = \sum_{j=0}^{n} \lambda_j x^j \in \mathbb{P}_n$ . Dann bezeichnet man  $\lambda_n$  als führenden Koeffizienten von p bzgl.

Falls j = 0 oder  $(\lambda_j \neq 0 \text{ und } \lambda_k = 0 \forall k > j)$ , so bezeichnet man  $\lambda_j$  als **Leitkoeffizient von** p.

**Satz 6** (Newtons Dividierte Differenzen). Seien  $a \leq x_0 < ... < x_n \leq b$  Stützstellen,  $y_j \in \mathbb{K}, p \in \mathbb{P}_n$  mit  $p(x_j) = y_j \forall j = 0, ..., n.$  Für  $j, m \in \mathbb{N}_0$  mit  $j + m \le n$  definiere

$$y_{j,0} := y_j y_{j,m} := \frac{y_{j+1,m-1} - y_{j,m-1}}{x_{j+m} - x_j}$$

- 1.  $y_{j,m}$  ist der führende Koeff. von  $p_{j,m} \in \mathbb{P}_m$  aus dem Neville-Verfahren.
- 2. Mit  $\lambda_j := y_{0,j}$  gilt  $p(x) = \sum_{j=0}^n \lambda_j \underbrace{\prod_{k=0}^{j-1} (x x_k)}_{=q_j \in \mathbb{P}_j}$  d.h. die dividierten Differenzen geben die Koeffizienten

des Int.pol. bzql. Newton-Basis.

*Proof.*  $q_k := p_{0,k} - p_{0,k-1} \in \mathbb{P}_n$  mit führendem Koeff.  $y_{0,k}$  und Nullstellen  $x_0, ..., x_{n-1}$  $\implies q_k = y_{0,k} \prod_{j=0}^{k-1} (x - x_j)$  nach Pol.div.

$$\implies p = p_{0,k} = p_{0,0} + \sum_{k=1}^{n} \underbrace{(p_{j,k} - p_{0,k-1})}_{=q_k} = y_{0,0} + \sum_{k=1}^{n} y_{0,k} \prod_{j=0}^{k-1} (x - x_j) = \sum_{k=0}^{n} \underbrace{y_{0,k}}_{=\lambda_k} \prod_{j=0}^{k-1} (x - x_j)$$

Schema der dividierten Differenzen

 $\implies$  arithmetischer Aufwand  $3\frac{n(n+1)}{2}$ , um alle  $y_{0,j}$  zu berechnen.

Bemerkung 14. • Die dividierten Differenzen sind ein Einschrittverfahren.

- Wenn man den y-Vektor überschreibt, braucht man keinen zusätzlichen Speicher.
- Das Verfahren löst das Vandermonde-System für die Newton-Basis, aber die Matrix aufzustellen.

• Die Auswertung von p(x) erfolgt mit Horner-Schema und Aufwand 3n pro  $x \in \mathbb{K}$ .

**Algorithmus 2.** Input: Stützstellen  $x_0 < ... < x_n$ , Funktionswerte  $y_0, ..., y_n \in \mathbb{K}$ 

- for m = 1 : n
- for j = n m : -1 : 0
- $y_{j,m} := \frac{y_{j+m} y_{j,m-1}}{x_{j+m} x_j}$
- $\bullet$  end
- end

Output: Koeffizienten des Interpol.pl.  $p \in \mathbb{P}_n$   $y_0, ..., y_n$  bzgl. Newton-Basis.

 $\begin{aligned} \textbf{Bemerkung 15.} & \textit{Will man das Interpolationspolynom } p(x) \textit{ an } N \textit{ Stellen auswerten, so gilt für den Gesamtaufwand: } Aufwand(Neville) = \frac{7}{2}Nn(n+1), \textit{ Aufwand(Div. Diff. + Horner)} = \underbrace{\frac{3}{2}n(n+1)}_{\textit{div. Diff.}} + \underbrace{\frac{3Nn}{Horner}}_{\textit{Horner}}. \end{aligned}$ 

Es gilt immer:  $Aufwand(Div.\ Diff.\ +\ Horner) \leq Aufwand(Neville)$ . Wenn man sich den Fortpflanzungsfehler anschaut dann sieht man aber, dass Neville weniger anfällig ist für Auslöschung.

In der Praxis verwendet man deshalb Neville für kleine N und Div. Diff. + Horner für große N.

### 2.5 Hermite-Polynominterpolation

Satz 7 (Wohlgestelltheit). Gegeben seien Stützstellen  $a \le x_0 < ... < x_n \le b$ , Funktionswerte  $y_j^{(k)} \in \mathbb{K}$  für j = 0, ..., n und  $k = 0, ..., n_j \in \mathbb{N}_0$  (Lagrange  $n_j = 0 \forall j$ ), Def  $N := \left(\sum_{j=0}^n (n_j + 1)\right) - 1$   $\implies Ex. \ eind. \ p \in \mathbb{P}_N \ mit \ p^{(k)}(x_j) = y_j^{(k)} \forall j = 0, ..., n, \forall k = 0, ..., n_j, \ wobei \ p^{(0)} = p$ .

*Proof.* Betrachte den Auswertungsoperator  $\mathcal{A}: \mathbb{P}_N \to \mathbb{K}^{N+1}, \mathcal{A}p := (p(x_0), ..., p^{(n_0)}(x_0), p(x_1), ..., p^{(n_1)}(x_1), ..., p^{(n_n)}(x_n))$  klar:  $\mathcal{A}$  ist linear und dim  $\mathbb{P}_N = N+1$ 

$$\Longrightarrow \mathcal{A} \text{ ist } \underbrace{\text{bijektiv}}_{=\text{Behauptung}} \text{, gdw. } \mathcal{A} \underbrace{\text{injektiv}}_{\text{zu zeigen!}} \underbrace{\text{(oder } \mathcal{A} \text{ ist surj)}}_{\text{"schwierig"}}.$$

Sei  $p \in \mathbb{P}_N$  mit  $\mathcal{A}p = 0$ , d.h.  $x_j$  eine  $(n_j + 1)$ -fache Nullstelle von  $p \forall j$ .  $\Longrightarrow p \in \mathbb{P}_N$  hat  $\sum_{j=0}^n (n_j + 1) = N + 1$  viele Nst. (bzgl. Vielfachheit)  $\Longrightarrow p = 0$ .

Bemerkung 16. • Der vorausgegangene Beweis ist das "normale Beweisprinzip" für lineare Interpolationsaufgaben. Klar: Man kann die Interpolationsaufgabe insb. lineares Gleichungssystem (äquivalent) formulieren.

- Neville-Verfahren und dividierte Differenzen lassen sich auch für das Hermite-Interpolationsproblem formulieren.
- Analog zu Lagrange (dieselbe Basis) kann man Fehlerdarstellung und Feherabschätzung beweisen, z.B.

$$|f(x) - p(x)| \le C_{\mathbb{K}} \frac{||f^{(N+1)}||_{L^{\infty}(a,b)}}{(N+1)!} \prod_{j=0}^{n} |x - x_j|^{n_j + 1}$$

 $C_{\mathbb{C}=\sqrt{2}}$  (vorher 2)

#### 2.6 Spline-Interpolation

Die Polynominterpolation erfordert hohe Glätte an f, um Fehlerabschätzung zu kriegen. Alternativ kann man deshalb stückweise Polynome betrachten (sog. Splines), um Verfahren und Fehlerkontrolle zu haben, falls f nicht so glatt ist.

**Beispiel 9** (affiner Interpolationspline). Zu Stützstellen  $a = x_0 < x_1 < ... < x_n = b$  und  $f \in \mathcal{C}[a,b]$  ist  $s \in \mathcal{C}[a,b]$  mit

- $s|_{[x_{i-1},x_i]} \in \mathbb{P}_1 \forall j = 1,...,n$
- $s(x_i) = f(x_i) \forall j = 0, ..., n$
- $\implies \textit{Offensichtlich eindeutig } s(x) = f(x_{j-1}) \frac{x-x_j}{x_{j-1}-x_j} + f(x_j) \frac{x-x_{j-1}}{x_j-x_{j-1}} \forall j \forall x \in [x_j-1,x_j]$

**Lemma 6.** Zu  $f \in \mathcal{C}[a,b] \cap \mathcal{C}^2[x_{j-1},x_j] \forall j=1,...,n$  sei  $s \in \mathcal{C}[a,b]$  der affine Interpolationsspline.  $Def h: [a,b] \to \mathbb{R}_{>0}, h|_{[x_{j-1},x_j]} := x_j - x_{j-1}$  lokale Netzweite  $\Longrightarrow ||f-s||_{L^{\infty}(a,b)} \le \frac{C_{\mathbb{R}}}{8} ||h^2 f''||_{L^{\infty}(a,b)}$ 

*Proof.* Sei  $x \in [x_{j-1}, x_j]$ 

$$\implies |f(x) - s(x)| \le C_{\mathbb{K}} \frac{||f''||_{L^{\infty}(x_{j-1}, x_{j})}}{2} \underbrace{\underbrace{|(x - x_{j-1})(x - x_{j})}_{\text{maximal für } x = \frac{x_{j-1} + x_{j}}{2}}}_{\text{maximal für } x = \frac{x_{j-1} + x_{j}}{2}}$$

$$\implies ||f - s||_{L^{\infty}(x_{j-1}, x_{j})} \le C_{\mathbb{K}} \frac{||f''||_{L^{\infty}(x_{j-1}, x_{j})}}{2} \cdot \frac{(x_{j} - x_{j-1})^{2}}{9} = \frac{C_{\mathbb{K}}}{8} ||h^{2}f''||_{L^{\infty}(x_{j-1}, x_{j})}$$

**Lemma 7.** Zu  $f \in C[a,b]$  und  $s \in C[a,b]$  affiner Int.spline

$$\implies (i)||f-s||_{L^{2}(a,b)} \leq ||hf'||_{L^{2}(a,b)}, \text{ sofern } f \in \mathcal{C}^{1}[x_{j-1},x_{j}] \text{ für alle } j$$
$$(ii)||f-s||_{L^{2}(a,b)} \leq ||h^{2}f||_{L^{2}(a,b)}, \text{ sofern } f \in \mathcal{C}^{2}[x_{j-1},x_{j}] \text{ für alle } j$$

*Proof.* zz: (i) elementweise für  $I_j = [x_{j-1}, x_j]$ 

$$F := f - s \in \mathcal{C}^{1}[x_{j-1}, x_{j}], h_{j} := x_{j} - x_{j-1}$$

$$F(x_{j-1}) = 0 \implies \int_{I_{j}} |F(x)|^{2} = \int_{I_{j}} \left| \int_{x_{j-1}}^{x_{j}} F' dx \right|^{2} \le h_{j}^{2} ||F'||_{L^{2}(I_{j})}^{2}$$

$$\implies ||F||_{L^{2}(I_{j})} \le h_{j} ||F'||_{L^{2}(I_{j})}$$

$$F(x_{j-1}) = 0 = F(x_{j}) \implies \int_{I_{j}} F' dx = 0$$

 $s'|_{I_i}$  konstant

$$\Rightarrow s'|_{I_j} = \frac{1}{h_j} \int_{I_j} f' dx \implies \langle f', s' \rangle_{L^2(I_j)} = ||s'||_{L^2(I_j)}^2$$

$$\Rightarrow ||F'||_{L^2(I_j)}^2 = ||f'||_{L^2(I_j)}^2 - 2Re \langle f', s' \rangle_{L^2(I_j)} + ||s'||_{L^2(I_j)}^2 = ||f'||_{L^2(I_j)}^2 - ||s'||_{L^2(I_j)}^2$$

$$\Rightarrow ||f - s||_{L^2(I_j)} = ||F||_{L^2(I_j)} \leq h_j ||F'||_{L^2(I_j)} \leq h_j ||f'||_{L^2(I_j)} = ||hf'||_{L^2(I_j)}$$

zz: (ii) elementweise

$$ReF(x_{j-1}) = 0 = ReF(x_j) \implies ReF'(\zeta) = 0 \text{ für } x_{j-1} < \zeta < x_j$$
  
 $|ReF'(x)| = |\int_I ReF''dt| \le h_j^{\frac{1}{2}} ||ReF''||_{L^2(I_j)}$ 

analog für ImF'

$$\implies \int_{I_j} |F'(x)|^2 \le h_j^2 ||F''||_{L^2(I_j)}^2 \implies ||F'||_{L^2(I_j)} \le h_j ||F''||_{L^2(I_j)}$$

$$\implies ||f - s||_{L^2(I_j)} \le h_j ||F'||_{L^2(I_j)} \le h_j^2 ||\underbrace{F''}_{=f'' \text{ auf } I_j} ||_{L^2(I_j)} = ||h^2 f''||_{L^2(I_j)}$$

(3) 
$$||f - s||_{L^2(a,b)}^2 = \sum_{j=1}^n ||f - s||_{L^2(I_j)}^2 \le \sum_{j=1}^n ||h^2 f''||_{L^2(I_j)}^2 = ||h^2 f''||_{L^2(a,b)}^2$$

**Definition 7.** Es sei  $\Delta = (x_0, ..., x_n)$  eine **Zerlegung von** [a, b], d.h.  $a = x_0 < ... < x_n = b$ . Zu gegebenen  $p, q \in \mathbb{N}_0$  hei $\beta t$   $s : [a, b] \to \mathbb{K}$  **Spline vom Grad** p **mit Glattheit** q, gdw.  $s \in \mathcal{C}^q[a, b]$  mit  $s|_{[x_{j-1}, x_j]} \in \mathbb{P}_p \forall j = 1, ..., n$ .

Schreibweise  $s \in \mathbb{S}_q^p(\Delta)$  bzw.  $s \in \mathbb{S}^p(\Delta)$ , falls q = p - 1.

Bemerkung 17. Die wichtigsten Beispiele sind affine Splines  $\mathbb{S}^1(\Delta)$ , quadratische Splines  $\mathbb{S}^2(\Delta)$ , kubische Splines  $\mathbb{S}^3(\Delta)$ .

Bemerkung 18. Für Wohlgestelltheit von Interpolationsaufgaben muss man dim  $\mathbb{S}_a^p(\Delta)$  bestimmen.

**Beispiel 10.** dim  $\mathbb{S}_1^p(\Delta) = \underbrace{n}_{Anz. \ Intervalle = \dim \mathbb{P}_p} \underbrace{(p+1)}_{= \dim \mathbb{P}_p} \widehat{=} \ global \ unstetige \ st \ddot{u}ckweise \ Polynome$ 

 $\dim \mathbb{S}_0^p(\Delta) = n(p+1) - (n-1) \widehat{=} \text{ global stetige stw. Polynome}$ 

 $\implies$  Bestimmung von Basen (und Dimension) von  $\mathbb{S}_{\sigma}^{p}(\Delta)$  ist komplizierter als bei Polynomräumen, lässt sich aber über sogn. B-Splines bewerkstelligen.

Bemerkung 19. Bei Splines hat man mehrere Möglichkeiten, um den Fehler ||f-s|| zu verringern

- h-Methode, d.h. die Zerlegung wird verfeinert
- p-Methode, d.h. man erhöht den Polynomgrad
- r-Methode, d.h. man erhält  $\#\Delta = n$ , aber man verschiebt die Stützstellen.

Zusätzlich kann man alles lokal kombinieren, z.B.

• hp-Methode: Verfeinere  $\Delta$ , wo f unglatt ist, und erhöhe p, wo f glatt ist.

**Satz 8.** Sei 
$$\Delta = (x_0, ..., x_n)$$
 Zerlegung von  $[a, b]$   $\implies \dim \mathbb{S}^p(\Delta) = n + p \text{ und } \mathcal{B} := \{x^j, \max\{x - x_k, 0\}^p | j = 0, ..., p, k = 1, ..., n - 1\}$  ist eine Basis.

*Proof.* klar:  $\mathcal{B} \subseteq \mathbb{S}^p(\Delta)$ 

(1) zz.  $\mathcal{B}$  ist lin. unabh.

Seien  $\lambda_j, \mu_j \in \mathbb{K}$  mit  $0 = \sum_{j=0}^p \lambda_j x^j + \sum_{k=1}^{n-1} \mu_k q_k$  klar: Auf [a,b] gilt  $q_k|_{[x_0,x_1]} = 0 \forall k=1,...,n-1 \implies \lambda_j = 0 \forall j=0,...,p$ , da Monome lin. unabh. auf  $[x_0, x_1].$ 

klar: Auf  $[x_1, x_2]$  gilt  $q_k|_{[x_1, x_2]} = 0 \forall k = 2, ..., n-1 \implies \mu_1 q_1 = 0$  auf  $[x_1, x_2], q_1(x_2) \neq 0 \implies \mu_1 = 0$ Induktives Vorgehen zeigt  $\mu_k = 0 \forall k = 1, ..., n-1$ 

(2) zz:  $\mathbb{S}^p(\Delta) \subseteq [\mathcal{B}]$ 

Sei  $s \in \mathbb{S}^p(\Delta)$ . Sei  $z_1 \in \mathbb{P}_p$  mit  $s|_{[x_0,x_1]} = z_1|_{[x_0,x_1]}$ .

Für k = 2, ..., n definiere sukzessive

$$z_k := z_{k-1} + \frac{s(x_k) - z_{k-1}(x_k)}{q_{k-1}(x_n)} q_{n-1} \in span(B)$$

zz.  $z_n = s$ 

Betrache Residuum  $r := s - z_n$ 

klar:  $r(x_k) = 0 \forall k = 0, ..., n$ 

Auf  $[x_0, x_1]$  gilt  $q_k|_{[x_0, x_1]} = 0 \forall k = 1, ..., n-1 \implies z_n|_{[x_0, x_1]} = z_1|_{[x_0, x_1]} = s|_{[x_0, x_1]} \implies r|_{[x_0, x_1]} = 0.$ Auf  $[x_1, x_2]$  gilt  $r \in \mathbb{P}_p$  mit  $r(x_1) = 0 = r(x_2)$ .  $r \in \mathcal{C}^{p-1}[a, b]$ , insb. (p-1)-mal stetig diffbar in  $x_1$ , d.h.  $x_1$ ist p-fache Nst. von r.  $\Longrightarrow p+1$  viele Nst. auf  $[x_1, x_2] \Longrightarrow r=0$  auf  $[x_1, x_2]$ .

Dasselbe Vorgegen auf allen Intervallen zeigt r = 0 auf [a, b].

Bemerkung 20. Sei  $\Delta = (x_0, ..., x_1)$  Zerlegung von [a, b] und  $s \in \mathbb{S}^p(\Delta)$  mit  $s(x_i) = y_i \forall j = 0, ..., n$ . Dann sind nur n+1 Bedingungen fixiert, aber dim  $\mathbb{S}^p(\Delta)=n+p$ , d.h. es fehlen noch p-1 Bedingungen für Wohlgestelltheit. Diese werden in der Regel als Randbedingungen formuliert, d.h. an Bedingungen an Ableitungen von s in a und b. Um diese symmetrisch zu stellen, müssen wir annehmen, dass p-1=2r gerade ist.

- (H) Hermite-Randbedingungen (oder vollständige Randbedingungen): Es werden s(j)(a), s(j)(b) $f\ddot{u}r \ j = 1, ..., r \ zusätzlich \ vorgegeben.$
- (N) Natürliche Randbedingungen:  $r \le n$  und  $s^{(j)}(a) = 0 = s^{(j)}(b)$  für j = r + 1, ..., 2r
- (P) Periodische Randbedingungen:  $s^{(j)}(a) = s^{(b)}$  für j = 1,...,2r
- 1. Zu p 1 = 2r und Randbedingungen (H), (P), (N) existiert (jeweils) ein eindeutiger Interpolationsspline  $s \in \mathbb{S}^p(\Delta)$ , der diese Randbedingung und  $s(x_j) = y_j \forall j = 0, ..., n$  wobei  $\Delta = (x_0, ..., x_n)$  und  $y_i \in \mathbb{K}$  gegeben.
  - 2. Erfüllt  $q \in \mathcal{C}^{(r+1)}[a,b]$  dieselben Interpolations- und Randbedingungen wie s, so gilt

$$||g^{(r+1)} - s^{(r+1)}||_{L^2(a,b)}^2 = ||g^{(r+1)}||_{L^2(a,b)}^2 - ||s^{(r+1)}||_{L^2(a,b)}^2$$

d.h. der Spline erfüllt die Minimaleigenschaft

$$||s^{(r+1)}||_{L^2(a,b)} \le ||g^{(r+1)}||_{L^2(a,b)}$$

3. Falls s (N) erfüllt, so muss g nur die Interpolationsbedingungen erfüllen!

Bemerkung 21. Für p=2 minimieren kubische Interpolationssplines also die Krümmungsenergie  $||s''||_{L^2(a,b)}^2$ . Daher kommt auch der Name Spline (dt: Biegestab)

Proof. (1) zz. (i) unter der Veraussetzung, dass (ii) gilt.

Seien  $s, \tilde{s} \in \mathbb{S}^p(\Delta)$  mit derselben Interpolations- und Randbedingungen. Aus (ii) folgt dann

$$||\tilde{s}^{(r+1)} - s^{(r+1)}||_{L^2(a,b)} = 0 \implies \rho := \tilde{s} - s \in \mathbb{P}_r$$

- (H)  $\rho(a) = 0$  und  $\rho^{(j)}(a) = 0$  für  $j = 1, ..., r \implies a$  ist (r+1)-fache Nullstelle  $\implies \rho = 0$
- (N)  $\rho(x_j) = 0$  für j = 0, ..., n und  $r \le n \implies$  mehr als r + 1 Nullstellen  $\implies \rho = 0$ (P)  $\rho^{(j)}(a) = \rho^{(j)}(b)$  für j = 1, ..., 2r.  $\rho \in \mathbb{P}_r \implies \rho^{(r-1)} \in \mathbb{P}_1$  und  $\rho^{(r-1)}(a) = \rho^{(r-1)}(b) \implies \rho^{(r-1)} \in \mathbb{P}_1$  $\mathbb{P}_0 \implies \rho \in \mathbb{P}_{r-1}$ . Induktiv  $\rho \in \mathbb{P}_0$  mit  $\rho(a) = 0 \implies \rho = 0$ .

Jetzt folgt mit Standardargumentation, dass der lineare Auswertungsoperator  $\mathcal{A}: \mathbb{S}^p(\Delta) \to \mathbb{K}^{n+p}$  bijektiv ist und aus Dimensionsgründen bijektiv. Insbesondere ist der Lösungsoperator  $\mathcal{L} = \mathcal{A}^{-1}$  bijektiv.

(ii) Betrachte  $|x-y|^2 = |x|^2 - 2Rex\bar{y} + |y|^2 = |x|^2 - |y|^2 - 2Re(x-y)\bar{y}$ 

$$\implies ||g^{(r+1)} - s^{(r+1)}||_{L^{2}(a,b)}^{2} = ||g^{(r+1)}||_{L^{2}(a,b)}^{2} - ||s^{(r+1)}||_{L^{2}(a,b)}^{2} - 2Re\underbrace{\int_{a}^{b} (g^{(r+1)} - s^{2}(r+1))\overline{s^{(r+1)}} dx}_{\text{zz:} = 0}$$

Wh:  $\int_a^b F'G + FG'dx = [FG]_a^b$ 

$$\int_{a}^{b} (g^{(r+1)} - s^{(r+1)}) \overline{s^{(r+1)}} dx = \left[ (g^{(r)} - s^{(r)}) \overline{s^{(r+2)}} dx \right]_{a}^{b} - \int_{a}^{b} (g^{(r)} - s^{(r)}) \overline{s^{(r+2)}} dx = \left[ (g^{(r)} - s^{(r)}) \overline{s^{(r+2)}} dx \right]_{a}^{b} - \left[ (g^{(r-1)} - s^{(r-1)}) \overline{s^{(r+2)}} dx \right]_{a}^{b} + \int_{a}^{b} (g^{(r-1)} - s^{(r-1)}) \overline{s^{(r+3)}} dx = \left[ \sum_{j=0}^{r-1} (-1)^{j} \left[ (g^{(r-j)} - s^{(r-j)}) \overline{s^{(r+1+j)}} \right]_{a}^{b} \right] + (-1)^{j} \int_{a}^{b} (g' - s') \overline{s^{(2r+1)}} dx = \overline{s^{(p)}} \leftarrow \text{ist konstant auf } [x_{j-1}, x_{j}] dx$$

$$\int_{a}^{b} (g' - s') \overline{s^{(p)}} dx = \sum_{j=1}^{n} \underbrace{\int_{x_{j-1}}^{x_{j}} (g' - s') \underbrace{\overline{s^{(p)}}}_{\in \mathbb{K}} dx}_{=\overline{s^{(p)}}_{[x_{j-1}, x_{j}]} \underbrace{\int_{x_{j-1}}^{x_{j}} (g' - s') dx}_{=[g - s]_{x_{j-1}}^{x_{j}} = 0}$$

(H) 
$$(g^{(r-j)} - s^{(r-j)})(\frac{a}{b}) = 0 \implies \sum (.) = 0$$

(N) 
$$s^{(r+1+j)}(\frac{a}{b}) = 0 \implies \sum_{i=1}^{n} (a_i) = 0$$

(N) 
$$\overline{s^{(r+1+j)}}(\frac{a}{b}) = 0 \implies \sum(.) = 0$$
  
(P)  $[g^{(r-j)}]_a^b = 0, [s^{(r-j)}]_a^b = 0 \implies \sum(.) = 0$ 

Bemerkung 22. Man kann mit Hilfe der sog. B-Splines Basen von allgemeineren Spline-Räumen konstruieren: Sei  $(t_j)_{j\in\mathbb{Z}}$  monoton steigend mit  $\lim_{j\to\pm\infty}t_j=\pm\infty$ .

 $Def \ B_{j,0} := \Xi_{[t_j,t_{j+1})} \ f\ddot{u}r \ p = 0, \ B_{j,p} := w_{j,p}B_{j,p-1} + (1-w_{j,p})B_{j+1,p-1} \ f\ddot{u}r \ p \geq 1 \ mit \ w_{j,p}(x) = \frac{x-t_j}{t_{j+p}-t_j} \ f\ddot{u}r$  $t_j < t_{j+p} \text{ und } w_{j,p}(x) = 0 \text{ für } t_j = t_{j+p}$ 

- Man kann zeigen, dass für  $t_j = x_j$  mit  $\Delta = (x_0, ..., x_n)$  Zerlegung von [a, b] gilt  $\mathbb{S}^p(\Delta) = span\{B_{j,p}|_{[a,b]}:$ j = p, ..., n - 1} und diese  $B_{j,p}$  bilden auch eine Basis (da n + p viele).
- Ferner haben die  $B_{j,p}$  "gute" Eigenschaften, z.B.  $B_{j,p} > 0$ ,  $supp(B_{j,p}) = [t_j, t_{j+p+1}], \sum_{j \in \mathbb{Z}} B_{j,p} = 1$ .
- Die Vielfachheit eines Knotens  $t_j = ... = t_{j+k}$  reduiert die Differenzierbarkeit der Splines bei  $t_k$  um k, d.h.  $\mathcal{C}^{p-(k+1)}$ -Differenzierbarkeit.

Übung: Sei  $s \in \mathbb{S}^p(\Delta)$  interpolierend  $s(x_j) = y_j$  mit natürlichen Randbedingungen ( $\leadsto$  "naives" Gleichungssystem mit Basis aus Satz wobei  $(n+3) \times (n+3)$  Gleichungssysteme mit vollbesetzter Vandermonde-Matrix). Auf  $[x_{j-1}, x_j]$  machen wir den Ansatz  $s|_{[x_{j-1}, x_j]} = a_0^{(j)} + a_1^{(j)}(x - x_j) + a_2^{(j)}(x - x_j)^2 + a_3^{(j)}(x - x_j)^3$ mit unbekannten Koeffizienten  $a_0^{(j)}, a_1^{(j)}, a_2^{(j)}, a_3^{(j)} \forall j = 1, ..., n.$ 

$$\implies a_0^{(j)} = y_j, a_1^{(j)} = \frac{y_j - y_{j-1}}{h_j} + \frac{h_j}{3} (2a_2^{(j)} + a_2^{(j-1)}), a_3^{(j)} = \frac{a_2^{(j)} - a_2^{(j-1)}}{3h_j}, h_j := x_j - x_{j-1} \text{ und } a_2^{(j)} = 0$$

TODO Matrix 07 27:32

Bemerkung 23. Für interpolierende Splines kann man Fehlerabschätzungen der Form  $||f-s||_{L^{\infty}(a,b)} \leq$  $Ch^{p+1}||f^{(p+1)}||_{L^{\infty}(a,b)}$  wobei  $h:=\max_{j}(x_{j}-x_{j-1})$ . Aber C>0 hängt an der Glattheit der Splines. Das ist technisch zu beweisen und hängt (natürlich) auch an den Randbdg.

#### 2.7Diskrete und schnelle Fourier-Transformation

Das Ziel dieses Abschnitts ist die Präsentation und Analyse des FFT-Algorithmus ("fast Fourier transform"), der in der Numerik einer der wichtigsten und vielfaltigsten Algorithmen ist. Unsere "Motivation" ist die einfachste Anwendung.

**Definition 8.** Wir bezeichnen  $\mathbb{T}_n := \{\sum_{j=0}^{n-1} \lambda_j \exp(ijx) | \lambda_0, ..., \lambda_{n-1} \in \mathbb{C} \}$  als Raum der trigonometrischen

Satz 10. 1. dim  $\mathbb{T}_{n-1} = n$ 

2. Zu Stützstellen  $0 \le x_0 < \dots < x_{n-1} \le 2\pi$  und Funktionswerten  $y_j \in \mathbb{C}$  ex. eind.  $p \in \mathbb{T}_{n-1}$  mit  $p(x_i) = y_i \forall i = 0, ..., n-1$ 

Proof. klar: dim  $\mathbb{T}_{n-1} \leq n$ Sei  $p(x) = \sum_{j=0}^{n-1} \lambda_j \exp(ijx) \in \mathbb{T}_n$  mit  $p(x_j) = 0 \forall j = 0, ..., n-1$ zz:  $\lambda_j = 0 \forall j = 0, ..., n-1$  (dann lin. unabh. und Eind. des Int.pol.)

Def 
$$z_k := \exp(ix_k) \in \mathbb{C}, \exp(ijx_k) = z_k^j$$
  $\Longrightarrow 0 = p(x_k) = \sum_{j=0}^{n-1} \lambda_j z_k^j =: \tilde{p}(z_n), \tilde{p} \in \mathbb{P}_{n-1} \implies \tilde{p} = 0, \text{ da } \tilde{p}n \text{ Nullstellen hat } \Longrightarrow \lambda_j = 0 \forall j = 0, ..., n-1.$ 

Im restlichen Abschnitt betrachten wir äquidistante Stützstellen (oder uniforme Stützstellen)  $x_k =$  $\frac{2\pi k}{n}$  für k=0,...,n-1. Dies führt auf zusätzliche Struktur der Vandermonde-Matrix, die durch FFT genutzt

**Satz 11.** Seien  $x_k = \frac{2\pi k}{n}, y_k \in \mathbb{C}$  gegeben für k = 0, ..., n - 1. Sei  $p \in \mathbb{T}_n$  das eind. trig. Int.pol. mit

Sei  $p(x) = \sum_{j=0}^{n-1} \lambda_j \exp(ijx)$  mit Koeff.  $\lambda_j \in \mathbb{C}$ . Def  $w_n := \exp(-\frac{2\pi i}{n})$  n-te Einheitswurzel und  $V_n \in \mathbb{C}^{n \times n}, V_n := (w_n^{jk})_{j,k=0}^{n-1}$  Fourier-Matrix (oder:

- 1.  $\frac{1}{n}V_ny = \lambda \text{ mit } y = (y_0, ..., y_{n-1}), \text{ d.h. } \lambda_j = \frac{1}{n}\sum_{k=0}^{n-1} w_n^{jk} y_k$
- 2.  $\frac{1}{\sqrt{n}}V_n$  ist symmetrisch und orthogonal, d.h.  $\left(\frac{1}{\sqrt{n}}V_n\right)^{-1} = \frac{1}{\sqrt{n}}\overline{V_n}$ .
- 3. Insb. ist  $W = \overline{V_n}$  die Vandermonde-Matrix der trigonometrischen Interpolation

*Proof.* (iii)  $\lambda$  ist Lösung des Vandermonde-Systems  $W\lambda = y$  mit

$$W = \begin{pmatrix} p_0(x_0) & \cdots & p_{n-1}(x_0) \\ \vdots & & \vdots \\ p_0(x_{n-1}) & \cdots & p_{n-1}(x_{n-1}) \end{pmatrix} \text{ mit } p_j = \exp(ijx)$$

 $W_{jk}=p_k(x_j)=\exp(ikx_j)=\exp\left(\frac{2\pi i}{n}jk\right)=w_n^{-jk}=(\overline{w_n})^{jk} \implies W=\overline{V_n}=W$  symmetrisch. Beweis (i), (ii): Sei  $W^{(k)}=(W_{jk})_{j=0}^{n-1}$  k-te Spalte von W.

$$W^{(k)} \cdot W^{(k)} = \sum_{j=0}^{n-1} W_{jk} \overline{W}_{jk} = \sum_{j=0}^{n-1} \underbrace{|W_{jk}|^2}_{-|y_{i}|^{2jk-1}} = n$$

Für k + l gilt

$$W^{(k)} \cdot W^{(l)} = \sum_{j=0}^{n-1} W_{jk} \overline{W_{jl}} = \sum_{j=0}^{n-1} \underbrace{w_n^{j(l-k)}}_{=(w_n^{(l-k)})^j = 0} = \frac{1 - (w_n^{(l-k)})^n}{1 - w_n^{(l-k)}}$$
$$(w_n^{(l-k)})^n = (w_n^n)^{l-k} = 1$$

 $\implies \frac{1}{\sqrt{n}}W$  ist symmetrisch und orthogonal und  $W^{-1} = \frac{1}{\sqrt{n}}\left(\frac{1}{\sqrt{n}}W\right)^{-1} = \frac{1}{n}\bar{W} = \frac{1}{n}V_n$ .

**Definition 9.** Die Abbildung  $\mathcal{F}: \mathbb{C}^n \to \mathbb{C}^n$ ,  $\mathcal{F}_n(x) = V_n x$  bezeichnet man als **diskrete Fourier-Transformation** (**DFT**) **der Länge** n. Die Inverse  $\mathcal{F}_n^{-1}\mathbb{C}^n \to \mathbb{C}^n$ ,  $\mathcal{F}_n^{-1}(x) = \frac{1}{n}\bar{V}_n x$  heißt **diskrete Fourier-Rücktransformation**.

Bemerkung 24. Die Skalierung von  $\mathcal{F}_n$  ist in der Literatur uneinheitlich. Manchmal  $\frac{1}{n}V_n, \frac{1}{\sqrt{n}}V_n$ , hier  $\mathcal{F}_n(x) = V_n x$ .

Satz 12. Für  $p \in \mathbb{N}$  und  $n = 2^p$  und  $m = \frac{n}{2}$  sei  $w_n := \exp(-\frac{2\pi i}{n})$ . Betrachte Permutation  $\sigma_n : \mathbb{C}^n \to \mathbb{C}^n$ ,  $\sigma_n(x) = (x_1, x_3, ..., x_{n-1}, \underbrace{x_2, x_4, ..., x_n})$ .

ungerade Indizes gerade Indizes

Für  $x \in \mathbb{C}^n$  definiere  $a, b \in \mathbb{C}^m$  durch  $a_j := x_j + x_{j+m}, b_j = (x_j - x_{j+m})w_n^{j-1}$  für  $j = 1, ..., m = \frac{n}{2}$ .  $\Rightarrow \sigma_n(\mathcal{F}_n(x)) = (\mathcal{F}_m(a), \mathcal{F}_m(b)), \ d.h.$  Auswertung von  $\mathcal{F}_n(x)$  wird auf Fourier-Trafo halber Länge  $\mathcal{F}_m(a), \mathcal{F}_m(b)$  zurückgeführt (+ Vertauschen).

Proof.

$$\mathcal{F}_n(y_0, ..., y_{n-1}) = \left(\sum_{l=0}^{n-1} w_n^{jl} y_l | j = 0, ..., n-1\right)$$
$$\mathcal{F}_n(x_1, ..., x_n) = \left(\sum_{l=0}^{n-1} w_n^{(j-1)l} x_{l+1} | j = 1, ..., n\right)$$

(1) zz: 
$$(\mathcal{F}_n(x))_{2j-1} = (\mathcal{F}_m(a))_j$$
  
klar:  $w_n^2 = w_m, w_m^m = 1$ 

$$\implies (\mathcal{F}_n(x))_{2j-1} = \sum_{l=0}^{n-1} w_n^{(2j-2)l} x_{l+1} = \sum_{l=0}^{m-1} \underbrace{(w_n^{2(j-1)l} x_{l+1} + \underbrace{w_n^{2(j-1)(l+m)}}_{=w_m^{(j-1)l}} x_{l+m+1})}_{=w_m^{(j-1)l}} = \underbrace{w_n^{2(j-1)(l+m)}}_{=1} x_{l+m+1} = \underbrace{w_n^{2(j-1)(l+m)}}_{=1} \underbrace{w_n^{2(j-1)(l+m$$

$$\sum_{l=0}^{m-1} w_m^{(j-1)l} \underbrace{(x_{l+1} + x_{l+m+1})}_{=a_{l+1}} = (\mathcal{F}_m(a))_j$$

$$(2) \text{ zz: } (\mathcal{F}_n(x))_{2j} = (\mathcal{F}_m(b))_j \\ \text{klar: } w_n^{(2j-1)l} = w_n^{2(j-1)l} w_n^l = w_m^{(j-1)l} w_n^l, \ w_n^{(2j-1)(l+m)} = w_n^{2(j-1)l} w_n^l \underbrace{w_n^{(2j-1)l}}_{=(w_n^{n/2})(2j+1)=-1} = -w_m^{(j-1)l} w_n^l$$

$$\implies (\mathcal{F}_n(x))_{2j} = \sum_{l=0}^{n-1} w_n^{(2j-1)} x_{l+1} = \sum_{l=0}^{n-1} \underbrace{(w_n^{(2j-1)l} x_{l+1} + w_n^{(2j-1)(l+m)} x_{l+m+1})}_{=w_m^{(j-1)l}} \underbrace{(x_{l+1} - x_{l+m+1}) w_n^l}_{=b_{l+1}} = (\mathcal{F}_m(b))_j$$

Bemerkung 25. In Matrixform kann man die FFT als Faktorisierung schreiben:

$$V_n = P_n \begin{pmatrix} V_{n/2} & 0 \\ 0 & V_{n/2} \end{pmatrix} \begin{pmatrix} I_{n/2} & I_{n/2} \\ D_{n/2} & -D_{n/2} \end{pmatrix}$$

 $mit \ P_n = (e_1, e_3, ..., e_{n-1}, e_2, e_4, ..., e_n) \in \mathbb{R}^{n \times n}, \ I_{n/2} \ Identit \ddot{a}t, \ D_{n/2} = diag(w_n^0, ..., w_n^{n-1}) \in \mathbb{C}^{n \times n}$ 

Korollar 2. Als Fast-Fourier-Transformation (FFT) bezeichnet man die rekursive Berechnung von  $\mathcal{F}_n(x)$  mit  $n=2^p$  mittels der Rekursion aus dem Satz. Die gesamte Rekursion behötigt weniger als  $\frac{3}{2}n\log_2 n$  arithmetische Operationen plus die Berechnung von  $w_n^l$  für l=0,...,n-1.

Proof. (1) Wegen  $w_{n/2}^l=w_n^{2l}$  reicht es, alle  $w_n^l$  für l=0,...,n-1 und das maximale n zu berechnen.

- (2) Beweis des arithm. Aufwands durch Induktion nach p.
- A(p) = Anzahl Additionen/Subtraktionen
- M(p) = Anzahl Multiplikationen

Beh: 
$$A(p) = p^{2^p}, M(p) \le \frac{1}{2}p^{2^p}$$
 (dann fertig, da Aufwand $(\mathcal{F}_n(x)) = A(p) + M(p) \le \frac{2}{3}p^{2^p} = \frac{3}{2}n\log_2 n$ )  
Ind.anf.  $p = 1, n = 2, ..., m - 1 \implies A(p) = 2, M(p) = 0 \checkmark$   
Ind.schritt: Die Aussage gelte für  $p$ , dann  $A(p+1) = 2\underbrace{A(p)}_{=p^{2^p}} + 2 \cdot 2^p = (p+1)2^{p+1} \checkmark. M(p+1) = 2\underbrace{M(p)}_{\le \frac{1}{2}p^{2^p}} + 2^p = \frac{1}{2}(p+1)2^{p+1} \checkmark$ 

Bemerkung 26. Die FFT ist eine schnelle Matrix-Vektor-Multiplikation für vollbesetzte Matrizen, die eine qewisse Struktur haben, ohne die Matrix jeweils voll aufzubauen, d.h. Speicherbedarf  $\mathcal{O}(n)$ .

UE:  $A \in \mathbb{K}^{n \times n}$  zirkulant, d.h.

$$A = \begin{pmatrix} a_0 & a_{n-1} & \cdot & a_1 \\ a_1 & a_0 & \cdot & \vdots \\ \vdots & \ddots & \vdots & \\ a_{n-1} & a_{n-2} & \cdot \cdot & a_0 \end{pmatrix}$$

 $\implies V_n A V_n^{-1} = D = diag(p(1), p(w_n), ..., p(w_n^{n-1})) \text{ mit } p(x) = \sum_{j=0}^n a_j x^j$ 

 $\implies$  klar: A ist regulär, gdw.  $p(w_n^j) \neq 0 \forall j = 0, ..., n-1$ 

Sei 
$$A$$
 zusätzlich regulär,  $b \in \mathbb{K}^k$ , Ziel: Löse  $Ax = b$   $\implies A = V_n^{-1}DV_n$ ,  $A^{-1} = V_n^{-1}D^{-1}V_n \implies x = V_n^{-1}D^{-1}V_nb = \frac{1}{n}\overline{V_n}D^{-1}V_nb$ ,  $\overline{V_n}\overline{y}$ 

Frage: Wie berechnet man die Diagonale von D effizient?

naiv:  $\mathcal{O}(n^2)$ , clever:  $V_n A = DV_n$ , insb.  $V_n a = D(1, ..., 1)^T = diag(D) \implies \text{FFT liefert } diag(D)$ .

Bemerkung 27. • Die FFT verdankt ihren Namen dem Zusammenhang mit der Fourier-Transformation: Für  $f \in L^2[0,2\pi]$  definiere  $\hat{f}(k) := \frac{1}{2\pi} \int_0^{2\pi} f(t) e^{-ikt} dt$  und  $S_n(t) := \sum_{k=-n}^n \hat{f}(k) e^{ikt}$ 

$$\implies \lim_n ||f - S_n||_{L^2(0,2\pi)} = 0 \text{ und } \frac{1}{2\pi} ||f||_{L^2(0,2\pi)}^2 = \sum_{k=-\infty}^{\infty} |\hat{f}(k)|^2$$

• Die trig. Interpolation ist auch für  $p(x) := \sum_{k=-n}^{n} c_k \exp(ikt)$  mit  $p(x_j) = y_j \forall j = -n, ..., n$  eind. lösbar,  $denn\ p(x) = \sum_{l=0}^{2n} c_{l-n} \underbrace{\exp(i(l-n)x)}_{=\exp(ilk)\exp(-inx)\neq 0}$ 

#### 3 Extrapolation

Bei einem Interpolationsproblem versucht man einen Funktionswert  $\Phi(x)$  zu approximieren mit  $x \in [x_0, x_n]$  und  $x_0 < ... < x_n$  Stützstellen. Bei der Extrapolation ist der einzige Unterschied, dass  $x \notin [x_0, x_n]$ .

#### Richardson-Extrapolation

Problemstellung:  $\Phi: [0,1] \to \mathbb{K}$  stetig und  $\Phi(h)$  berechenbar für h > 0, Ziel: Approximiere  $\Phi(0)$ 

**Algorithmus 3.** Input: Die stetige Funktion  $\Phi$  habe eine asympotische Entwicklung

$$\Phi(h) = \Phi(0) + \sum_{j=1}^{n} a_j h^{\alpha j} + \mathcal{O}(h^{\alpha(n+1)})$$

 $f\ddot{u}r\ h > 0 \ und \ n \in \mathbb{N}, \ wobei \ \alpha > 0 \ bekannt, \ aber \ \Phi(0) \ und \ a_1, ..., a_n \ unbekannt.$ 

Prozedur: Berechne  $\Phi(h_j)$  für  $h_0 > ... > h_n$  und werte das eindeutige  $p_n \in \mathbb{P}_n$  mit  $p_n(h_j^{\alpha}) = \Phi(h_j) \forall j = 0$ 0,...,n mittels Neville-Verfahren bei h=0 aus, d.h.  $\Phi(0)\approx p_n(0)$ .

Bemerkung 28. Meist versucht man kein fixes n, sondern iteriert, bis  $p_{n+1}(0) \approx p_n(0)$ . Dabei nutzt die Implementierung, dass man das Neville-Verfahren "leicht" um den Knoten  $(h_{n+1}^{\alpha}, \Phi(h_{n+1}))$  erweitern kann.

**Bemerkung 29.** Aus der asymp. Entwicklung folgt, dass  $|\Phi(0) - \Phi(h)| = \mathcal{O}(h^{\alpha})$ , sofern  $a_1 \neq 0$ , und  $\alpha > 0$  ist nicht verbesserbar, d.h. maximale Konvergenzordnung.

**Beispiel 11** (einseitiger Diff.quotient).  $\Phi(h) = \frac{f(x+h)-f(x)}{h}$  für h > 0 und  $\Phi(0) = f'(x)$ .

$$Taylor \implies f(x+h) = f(x) + \sum_{j=1}^{n+1} \frac{f^{(j)}(x)}{j!} h^{j} + \mathcal{O}(h^{n+2})$$

$$\implies \underbrace{\frac{f(x+h) - f(x)}{h}}_{=\Phi(h)} = \underbrace{f'(x)}_{p=\Phi(0)} + \underbrace{\sum_{j=2}^{n+1} \frac{f^{(j)}(x)}{j!} h^{j-1}}_{=\sum_{k=1}^{n} \underbrace{\frac{f^{(k+1)}(x)}{(k+1)!}}_{h^{k}} h^{k}$$

und  $\alpha = 1$ .

Beispiel 12 (zentraler Diff.quotient).  $\Phi(h) = \frac{f(x+h) - f(x-h)}{2h}$  für h > 0 und  $\Phi(0) = f'(x)$ . Taylor:  $f(x \pm h) = \sum_{j=0}^{2n+2} \frac{f^{(j)}(x)}{j!} (\pm h)^j + \mathcal{O}(h^{2n+3})$ 

$$\Rightarrow \Phi(h) = \frac{1}{2n} \left( \sum_{j=0}^{2n+2} \frac{f^{(j)}(x)}{j!} \underbrace{\int_{j=0}^{n} \frac{(h^j - (-h)^j)}{gerade, = 2h^j \ f\"{u}r \ j \ ungerade}} \right) + \mathcal{O}(h^{2n+3}) \right) = \frac{1}{2n} \left( \sum_{l=1}^{n+1} \frac{f^{(2l-1)}(x)}{(2l-1)!} h^{2(l-1)} + \mathcal{O}(h^{2n+3}) \right) = \underbrace{\int_{j=0}^{n} \frac{f^{(2l-1)}(x)}{(2l-1)!} h^{2(l-1)}}_{=\sum_{k=1}^{n} \frac{f^{(2(k+1)-1)}(x)}{(2(k+1)-1)!} h^{2k} + \mathcal{O}(h^{2(n+1)}) \right) + \mathcal{O}(h^{2n+2})$$

 $\implies$  asymp. Entwicklung mit  $\alpha = 2$ .

**Algorithmus 4** (Richardson Extrapolation). Die stetige Funktion  $\Phi:[0,1]\to\mathbb{K}$  erfülle  $\Phi(h)=\Phi(0)+$  $\sum_{j=1}^{\bar{n}} a_j h^{\alpha j} + \mathcal{O}(h^{\alpha(n+1)}) \text{ für } h > 0, \text{ wobei } \alpha > 0 \text{ bekannt, } \Phi(0), a_1, ..., a_n \text{ unbekannt. Sind für } h_0 > ... > h_n \text{ die } h_0 >$ Funktionswerte  $\Phi(h_j)$  bekannt, so sei  $p \in \mathbb{P}_n$  mit  $p(h_j^{\alpha}) = \Phi(h_j) \forall j = 0, ..., n$ . Verwende Neville-Verfahren, um  $p(0) \approx \Phi(0)$ .

Beispiel 13. • einseitiger Diff. quotient  $\alpha = 1$ 

• zentraler Diff.quotient  $\alpha = 2$ 

**Beispiel 14** (Romberg-Verfahren). Sei  $f \in \mathcal{C}[a,b], \Phi(0) = \int_a^b f dx$ .  $\Phi(h) = \frac{h}{2} \left( f(a) + 2 \sum_{j=1}^{n-1} f(x_j) + f(b) \right)$  $mit \ h = \frac{b-a}{n}, x_j := a+jh, \ sog. \ summierte \ Trapezregel \ \implies \Phi(h) = \Phi(0) + \sum_{j=1}^n a_j h^{2j} + \mathcal{O}(h^{2(n+1)}) \ gilt, \ sog. \ Euler-Maclaurin'sche Summenformel. \ Romberg-Verfahren = Anwendung von Richardson-Extrapol. \ auf summierte \ Trapezregel.$ 

**Satz 13.** Mit  $C>0, \alpha>0$  erfülle  $\Phi:[0,1]\to\mathbb{K}$  die Entwicklung  $\Phi(h)=\Phi(0)+\sum_{j=1}^n a_jh^{\alpha j}+a_{n+1}(h)$  mit  $|a_{n+1}(h)| \le Ch^{\alpha(n+1)} \forall h > 0.$ 

$$Es \ sei \ 0 < q < 1 \ und \ h_k = q^k \ f\"{u}r \ k = 0, ..., n. \ Sei \ p \in \mathbb{P}_n \ mit \ p(h_j^{\alpha}) = \Phi(h_j) \forall j = 0, ..., n.$$

$$\implies |\Phi(0) - p(0)| \le Mq^{\alpha \frac{n(n+1)}{2}} \ mit \ M = C \underbrace{\frac{1}{1 - q^{\alpha}} \exp\left(\frac{2q^{\alpha}}{(1 - q^{\alpha})^2}\right)}_{unabh\"{a}ngig \ vom \ Restglied}$$

• Unter der Vorraussetzung des Satzes gilt  $|\Phi(0) - \Phi(h_n)| = \mathcal{O}(h_n^{\alpha}) = \mathcal{O}(q^{\alpha n})$  bei naiver Bemerkung 30. Realisierung;  $|\Phi(0) - p(0)| = \mathcal{O}(q^{\alpha n^2})$  durch Extrapolation.  $\implies$  wesentlich kleineres n nötig, um dieselbe Genauigkeit zu erhalten. Man sagt "Extrapolation mindert Auslöschung".

• Achtung: Die Richardson-Extrapolation ist nur sinnvoll, wenn man  $\alpha > 0$  kennt!

Proof. (1) zz:  $|\Phi(0) - p(0)| \le C \sum_{l=0}^{n} q^{\alpha l(n+1)} |L_l(0)| \text{ mit } L_l(x) = \prod_{k=0, k \ne l}^{n} \frac{x - x_l}{x_k - x_l}, x_k = h_k^{\alpha} = q^{\alpha k}$ 

$$p(x) = \sum_{l=0}^{n} \underbrace{\Phi(h_l)}_{\text{asymp. Entwicklung} L_l(x)} = \Phi(0) \underbrace{\sum_{l=0}^{n} L_l(x)}_{=1} + \underbrace{\sum_{j=1}^{n} a_j \sum_{l=0}^{n} (h_l^{\alpha j})}_{=x^j} + \sum_{l=0}^{n} a_{n+1}(h_l) L_l(x) = \underbrace{\Phi(0) + \sum_{j=1}^{n} a_j x^j}_{=x^j} + \underbrace{\sum_{l=0}^{n} a_{n+1}(h_l) L_l(x)}_{=x^j}$$

$$\implies |p(0) - \Phi(0)| \le \sum_{l=0}^{n} \underbrace{|a_{n+1}(h_l)|}_{\le Ch_l^{\alpha(n+1)} = Cq^{\alpha l(n+1)}} |L_l(0)|$$
(2) zz:  $|L_l(0)| = q^{-l\alpha(n+1)}q^{+\frac{\alpha n(n+1)}{2}} \prod_{k=0, k \ne l}^{n} \frac{1}{|1 - q^{(k-l)\alpha}|}$ 

(2) zz: 
$$|L_l(0)| = q^{-l\alpha(n+1)}q^{+\frac{\alpha n(n+1)}{2}} \prod_{k=0, k \neq l}^n \frac{1}{|1-q^{(k-l)\alpha}|}$$

$$|L_l(0)| = \prod_{k=0, k \neq l}^n \frac{|x_k|}{|x_l - x_k|} = \frac{\prod_{k \neq l} q^{\alpha k}}{\prod_{k \neq l} |q^{\alpha l} - q^{\alpha k}|}$$

$$\prod_{k \neq l} q^{\alpha k} = q^{-lk} \prod_{k=0}^{n} q^{\alpha k} = q^{-lk} q^{\alpha \sum_{k=0}^{n} k} = q^{-lk} q^{\alpha \frac{n(n+1)}{2}}$$

$$\prod_{k \neq l} |q^{\alpha l} - q^{\alpha k}| = \prod_{k \neq l} (q^{\alpha l} |1 - q^{\alpha (k-l)}|) = \underbrace{\left(\prod_{k \neq l} q^{\alpha l}\right)}_{=q^{\alpha l n}} \left(\prod_{k \neq l} |1 - q^{\alpha (k-l)}\right)$$

(3) zz: 
$$\prod_{k=0, k \neq l}^{n} \frac{1}{|1-q^{(k-l)\alpha}|} \leq q^{\alpha \frac{l(l+1)}{2}} \prod_{k=1}^{n} \frac{1}{(1-q^{k\alpha})^2}$$
 Betrache 
$$\{k-l|k=0,...,n \text{ mit } k \neq l\} = \{-l,...,-1\} \cup \{1,...,n-l\}$$

$$\implies \prod_{k=0,k\neq l}^{n} |1-q^{(k-l)\alpha}| = \underbrace{\left(\prod_{k=1}^{n-l} \underbrace{|1-q^{k\alpha}|}_{=(1-q^{k\alpha})}\right)}_{\geq \prod_{k=1}^{n} (1-q^{k\alpha})} \left(\prod_{k=1}^{l} \underbrace{|1-q^{-k\alpha}|}_{=|1-\frac{1}{q^{k\alpha}}| = \frac{1-q^{k\alpha}}{q^{k\alpha}}}\right) \geq$$

$$\prod_{k=1}^n (1-q^{k\alpha}) \prod_{k=1}^l q^{-k\alpha} \prod_{k=1}^l (1-q^{k\alpha}) = \prod_{k=1}^n (1-q^{k\alpha})^2 q^{-\alpha \frac{l(l+1)}{2}}$$

(4) zz: 
$$\prod_{k=1}^{n} \frac{1}{(1-q^{k\alpha})^2} \le \exp\left(\frac{2q^{\alpha}}{(1-q^{\alpha})^2}\right)$$

$$\log\left(\prod_{k=1}^n\frac{1}{(1-q^{k\alpha})^2}\right) = 2\sum_{k=1}^n\log\underbrace{\left(\frac{1}{1-q^{k\alpha}}\right)}_{=1+\frac{q^{k\alpha}}{1-q^{k\alpha}}} \leq 2\sum_{k=1}^n\frac{q^{k\alpha}}{1-q^{k\alpha}} \leq 2\frac{1}{1-q^\alpha}\sum_{\substack{k=1\\ \leq \frac{q^\alpha}{1-q^\alpha}}}^nq^{k\alpha} \leq 2\frac{q^\alpha}{(1-q^\alpha)^2}$$

(5)

$$|p(0) - \Phi(0)| \stackrel{(1)}{\leq} C \sum_{l=0}^{n} q^{l\alpha(n+1)} \underbrace{|L_{l}(0)|}_{\stackrel{(2)}{\leq} q^{-l\alpha(n+1)} q^{\alpha}} \stackrel{\underline{L_{l}(0)}|}{\prod_{k \neq l} \frac{1}{|1 - q^{(k-l)\alpha}|}} \leq Cq^{\alpha \frac{n(n+1)}{2}} \sum_{l=0}^{n} \underbrace{\prod_{k \neq l} \frac{1}{|1 - q^{(k-l)\alpha}|}}_{\stackrel{(3)}{\leq} q^{\alpha} \frac{l(l+1)}{2}} \stackrel{\underline{L_{l}(0)}|}{\prod_{k \neq l} \frac{1}{|1 - q^{(k-l)\alpha}|}} \leq \left[ C \exp\left(\frac{2q^{\alpha}}{(1 - q^{\alpha})^{2}}\right) \underbrace{\sum_{l=0}^{n} q^{\alpha \frac{l(l+1)}{2}}}_{\stackrel{(3)}{\leq} q^{\alpha} \frac{l(l+1)}{2}} \right] q^{\alpha \frac{n(n+1)}{2}} e^{\frac{1}{\alpha} \frac{1}{(1 - q^{k\alpha})^{2}}} e^{\frac{1}{\alpha} \frac$$

#### Aitken'sches $\Delta^2$ -Verfahren 3.2

Beim  $\Delta^2$ -Verfahren handelt es sich um ein Verfahren zur Konvergenzbeschleunigung, d.h. sei  $(x_n)_{n\in\mathbb{N}\subset\mathbb{K}}$ eine bekannte, konvergente Folge mit unbekanntem Limes  $x = \lim_{n \to \infty} x_n$ 

Ziel: Konstruiere eine Folge  $(y_n)_{n\in\mathbb{N}}$  mit  $\lim_{n\to\infty}\frac{x-y_n}{x-x_n}=0$ , d.h.  $(y_n)$  konvergiert schneller gegen x.

**Bemerkung 31.** Sei  $(x_n)_{n\in\mathbb{N}}$  eine geometrisch konvergente Folge mit Limes x, d.h. ex.  $q\in\mathbb{K}$  mit |q|<1 und  $x - x_{n+1} = q(x - x_n) \forall n \in \mathbb{N}$ 

klar:  $\lim_{n \to \infty} x_n = x$ 

Betrachte Differenzenoperator  $\Delta y_n := y_{n+1} - y_n$   $zz: x = x_n - \frac{(\Delta x_n)^2}{\Delta^2 x_n} = x_n - \frac{(x_{n+1} - x_n)^2}{\Delta (x_{n+1} - x_n)} = x_n - \frac{(x_{n+1} - x_n)^2}{x_{n+2} - 2x_{n+1} + x_n}$ , d.h. Limes x kann aus x Folgegliedern  $x_n, x_{n+1}, x_{n+2}$  exakt berechnet werden.

Proof.

$$x_{n+2} - 2x_{n+1} + x_n = (x_{n+2} - x) - 2(x_{n+1} - x) + (x_n - x) = \underbrace{[q^2 - 2q + 1]}_{\neq 0} \underbrace{(x_n - x)}_{\neq 0 \text{ o.B.d.A}}$$
$$\left(x_n - \frac{(\Delta x_n)^2}{\Delta^2 x_n}\right) - x = (x_n - x) - \frac{(q - 1)^2 (x_n - x)^2}{(q - 1)^2 (x_n - x)} = 0$$

Satz 14. Sei  $(x_n)_{n\in\mathbb{N}}\subset\mathbb{K}$  mit  $x_n\neq x\in\mathbb{K}$  und  $x_{n+1}-x=(q+\delta_n)(x_n-x)\forall n\in\mathbb{N}$  mit  $q\in\mathbb{K}, |q|<1, (\delta_n)_{n\in\mathbb{N}}\subset\mathbb{K}$  $\mathbb{K} \ mit \ \lim_n \delta_n = 0.$ 

1.  $\lim_n x_n = x$ 

2. Ex.  $n_0 \in \mathbb{N}$ , sodass  $y_n := x_n - \frac{(\Delta x_n)^2}{\Delta^2 x_n} \in \mathbb{K}$  wohldef. für  $n \ge n_0$ 

3.  $\lim_{n} \frac{x - y_n}{x - x_n} = 0$ 

*Proof.* (i) Sei  $0 < |y| < \kappa < 1$ . Wegen  $\lim_n \delta_n = 0$ , ex.  $\tilde{n}_0 \in \mathbb{N}$  mit  $|q + \delta_n| \le \kappa \forall n \ge \tilde{n}_0$  $\implies |x_{n+1} - x| \le \underbrace{|q + \delta_n|}_{\le x} |x_n - x| \implies \lim_n |x_{n+1} - x| = 0 \implies x = \lim_n x_n$ 

(ii)

$$x_{n+2} - 2x_{n+1} + x_n = (x_n - x) \underbrace{\left[ (q + \delta_{n+1})(q + \delta_n) - 2(q + \delta_n) + 1 \right]}_{=(q - 1)^2} + \underbrace{\left( \delta_n \delta_{n+1} + q(\delta_n + \delta_{n+1} - 2\delta_n) \right)}_{=:\epsilon_n \to 0}$$

(iii)

$$y_n - x = (x_n - x) - \frac{(x_{n+1} - x_n)^2}{(x_n - x)[(q-1)^2 + \epsilon_n]} = (x_n - x) - \frac{(q + \delta_n - 1)^2 (x_n - x)^2}{(x_n - x)[(q-1)^2 + \epsilon_n]} = (x_n - x) \left(1 - \frac{(q-1 + \delta_n)^2}{(q-1)^2 + \epsilon_n}\right)$$

$$\implies \frac{y_n - x}{x_n - x} = 1 - \frac{(q-1 + \delta_n)}{(q-1)^2 + \epsilon_n} \to 0$$

Bemerkung 32. Die Vorraussetzungen von Aitken sind defakto für jedes numerische Verfahren erfüllt, d.h. bevor man nichts macht und naiv  $(x_n)$  betrachtet, macht man immer Aitken.

**Beispiel 15** (einseitiger Diff.quot.).  $f \in C^2(\mathbb{R}), z \in \mathbb{R}, h_n > 0$ 

Taylor 
$$\implies f(z+h) = f(z) + h_n f'(z) + \frac{h_n^2}{2} f''(\zeta_n)$$
 mit  $z < \zeta_n < z + h_n$ 

$$\implies \underbrace{f'(z)}_{=:x} - \underbrace{\frac{f(z+h) - f(z)}{h_n}}_{=:x_n} = h_n \left( -\frac{f''(\zeta_n)}{2} \right) = h_n \left( -\frac{f''(z)}{2} + \underbrace{\frac{f''(z) - f''(\zeta_n)}{2}}_{=:\epsilon_n} \right)$$

П

$$\epsilon_n \to 0$$
 für  $h_n \to 0$   
In der Praxis  $h_n := 2^{-n}h_0$   
Für  $f''(x) \neq 0$ 

$$\implies x - x_{n+1} = h_{n+1} \left( -\frac{f''(z)}{2} + \epsilon_{n+1} \right) = \underbrace{\frac{1}{2}}_{=:q} \underbrace{\frac{-\frac{f''(z)}{2} + \epsilon_{n+1}}{2}}_{=1 + \underbrace{\frac{\epsilon_{n+1} - \epsilon_n}{2} + \epsilon_n}}_{=: \frac{\delta_n}{2}} (x - x_n)$$

#### Numerische Integration 4

Im ganzen Kapitel seien  $a, b \in \mathbb{R}$  mit a < b. Ferner sei  $w \in L^1(a, b)$  eine Gewichtsfunktion mit w(x) > 0 fast

Ziel: Approximiere  $Qf := \int_a^b fw dx$  für  $f \in \mathcal{C}[a,b]$ 

**Bemerkung 33.** Soll eine Funktion  $g \in L^1(a,b)$  numerisch integriert werden, so zerlegt man g = fw mit fdem glatten Anteil von g und w dem singulären Anteil, z.B.  $g(x) = \frac{\sin x}{\sqrt{1-x^2}}$ , dann  $f(x) = \sin(x)$ ,  $w(x) = \frac{1}{\sqrt{1-x^2}}$ analog  $g(x) = x \log x$ , dann f(x) = x,  $w(x) = \log x$ .

#### 4.1 Quadraturformeln

**Definition 10.** Gegeben seinen Stützstellen (oder: Quadraturknoten)  $a \le x_0 < ... < x_n \le b$  und Gewichte  $w_0,...,w_n \in \mathbb{K}$ . Dann bezeichnet man  $Q_n f = \sum_{j=0}^n w_j f(x_j)$  als Quadraturformel (der Länge n).  $Q_n$  hat **Exaktheitsgrad**  $m \in \mathbb{N}_0$ , gdw.  $Q_n p = Qp$  für alle  $p \in \mathbb{P}_m$ , d.h. Polynome vom Grad m werden exakt integriert.

1.  $Q, Q_n$  sind linear und stetig auf  $\mathcal{C}[a,b]$  mit Operatornorm  $||Q|| := \sup_{f \in \mathcal{C}[a,b], f \neq 0} \frac{|Qf|}{||f||_{L^{\infty}(a,b)}} =$ Lemma 8.  $||w||_{L^1(a,b)}, ||Q_n|| = \sum_{j=0}^n |w_j|$ 

- 2. Der Exaktheitsgrad von  $Q_n \leq 2n + 1$
- 3. Ist  $Q_n$  exakt auf  $\mathbb{P}_{2n+1}$ , so gibt es kein  $p \in \mathbb{P}_{2n+2} \setminus \mathbb{P}_{2n+1}$  mit  $Q_n p = Q p$
- 4. Ist  $Q_n$  exakt auf  $\mathbb{P}_0$ , so gilt  $\sum_{i=0}^n w_i = ||w||_{L^1(a,b)}$
- 5. Für w(x) = 1 und  $Q_n$  exakt auf  $\mathbb{P}_1$ , so gilt  $\sum_{j=0}^n w_j = b a$ ,  $\sum_{j=1}^n w_j x_j = \frac{b^2 a^2}{2}$

Bemerkung 34. Oft verwendet man banale Identitäten wie (iv), (v) um zu testen, ob eine Quadratur korrekt implementiert ist.

Proof. (i) klar: 
$$|Qf| \le ||f||_{L^{\infty}(a,b)} ||w||_{L^{1}(a,b)}$$
  
 $\implies ||Q|| \le ||w||_{L^{1}(a,b)}$ 

klar: 
$$|Q_n f| \le \sum_{j=0}^n |w_j| |f(x_j)| \le ||f||_{L^{\infty}(a,b)} \sum_{j=0}^n |w_j|$$

$$\implies ||Q_n|| \le \sum_{j=0}^n |w_j|$$

 $\Rightarrow ||Q|| \le ||w||_{L^{1}(a,b)}$   $||Q|| \le ||w||_{L^{1}(a,b)}$   $||Q|| \le \sum_{j=0}^{n} |w_{j}||f(x_{j})| \le ||f||_{L^{\infty}(a,b)} \sum_{j=0}^{n} |w_{j}|$   $\Rightarrow ||Q_{n}|| \le \sum_{j=0}^{n} |w_{j}|$ Wähle einen Polygonzug  $f \in \mathcal{C}[a,b]$  mit  $||f||_{L^{\infty}(a,b)} \le 1$  mit  $w_{j}f(x_{j}) = |w_{j}|$ , d.h.  $f(x_{j}) = signw_{j}$  also  $|f(x_j)| \le 1$ 

$$\implies Q_n f = \sum_{j=0}^n w_j f(x_j) \implies ||Q_n|| = \sum_{j=0}^n |w_j|$$

(ii) Wähle 
$$p(x) = \prod_{i=0}^{n} (x - x_i)^2$$
.  $p \in \mathbb{P}_{2n+2}$  und  $p > 0$  fü

$$\Rightarrow Q_n f = \sum_{j=0}^n w_j f(x_j) \Rightarrow ||Q_n|| = \sum_{j=0}^n |w_j|$$
(ii) Wähle  $p(x) = \prod_{j=0}^n (x - x_j)^2$ .  $p \in \mathbb{P}_{2n+2}$  und  $p > 0$  fü
$$\Rightarrow Qf = \int_a^b \underbrace{pw}_{>0 \text{ fü}} dx > 0 = Q_n p$$

 $\implies p$  wird nicht exakt integriert  $\implies$  Exaktheit $(Q_n) \le 2n + 1$ 

(iii)  $R := Q - Q_n$  linear. Sei  $\{p_0, ..., p_{2n+1}\} \subseteq \mathbb{P}_{2n+1}$  Basis. Falls  $p_{2n+2} \in \mathbb{P}_{2n+1}$ , so ist  $\{p_0, ..., p_{2n+2}\} \subseteq \mathbb{P}_{2n+1}$  $\mathbb{P}_{2n+2}$  Basis.

Es gilt R = 0 auf  $\mathbb{P}_{2n+2}$  gdw.  $R(p_j) = 0 \forall j = 0, ..., 2n + 2$ 

(iv) 
$$||w||_{L^1(a,b)} = Q1 = Q_n 1 = \sum_{j=0}^n w_j$$

Es gilt 
$$R = 0$$
 auf  $\mathbb{P}_{2n+2}$  gdw.  $R(p_j) = 0 \forall j = 0, ..., 2n+2$   
(iv)  $||w||_{L^1(a,b)} = Q1 = Q_n 1 = \sum_{j=0}^n w_j$   
(v) Für  $w = 1$  gilt  $||w||_{L^1(a,b)} = b - a$ ,  $Qx = Q_n x = \sum_{j=0}^n w_j x_j$ , da  $Q_n$  exakt auf  $\mathbb{P}_1$  und  $x$  ein smom  $\in \mathbb{P}_1$ .

Monom  $\in \mathbb{P}_1$ .

Achtung: Meistens verwendet Quadratur den Laufindex j=0,...,n (d.h. n+1 Stützstellen, Exaktheit  $\leq 2n+1$ ). Manchmal wird aber j=1,...,n betrachtet, d.h. n Stützstellen, Exaktheit  $\leq 2n-1$ .

**Bemerkung 35.** In der Literatur (z.B. Abramowitz oder Secrest-Strand) sind Quadraturformeln auf Standard-intervallen tabelliert, z.B. [0,1],[-1,1]. Um Quadraturformeln auf [a,b] zu erhalten, verwendet man in der Regel eine affine Transformation:

$$\Phi: [-1,1] \to [a,b], \Phi(t) = \frac{1}{2} \{a+b+t(b-a)\}$$

$$\implies \int_{a}^{b} fw dx = \int_{-1}^{1} f(\Phi(x)) \underbrace{w(\Phi(x))}_{=:\tilde{w}(x)} \underbrace{|\det D\Phi(x)|}_{\frac{b-a}{2}} dx =$$

$$\underbrace{\frac{b-a}{2} \tilde{Q}(f \circ \Phi)}_{=:w_{j}} \approx \underbrace{\frac{b-a}{2} \tilde{Q}_{n}(f \circ \Phi)}_{=:w_{j}} = \sum_{j=0}^{n} w_{j} f(x_{j}) =: Q_{n} f$$

analog für  $\Phi: [0,1] \to [a,b], \Phi(t) = a + t(b-a)$ klar: Falls  $f \in \mathbb{P}_m$ , dann  $f \circ \Phi \in \mathbb{P}_m \implies Exaktheit(\tilde{Q}_n) = Exaktheit(Q_n)$ 

Satz 15 (Fehlerabschätzung + Konvergenz). Sei  $Q_n f = \sum_{j=0}^n w_j^{(n)} f(x_j^{(n)})$  eine Quadraturformel der Länge n und Exaktheit m.

$$\implies |Qf - Q_n f| \le (||w||_{L^1(a,b)} + \sum_{i=0}^n |w_j^{(n)}|) \min_{p \in \mathbb{P}_m} ||f - p||_{L^{\infty}(a,b)}$$

Ferner sind äquivalent:

- $Qf = \lim_{n \to \infty} Q_n f \forall f \in \mathcal{C}[a, b]$
- $Qp = \lim_{n \to \infty} Q_n p \forall p \in \mathbb{P} := \bigcup_{n \in \mathbb{N}} \mathbb{P}_n \text{ und } \sup_{n \in \mathbb{N}} \sum_{j=0}^n |w_j^{(n)}| < \infty.$

*Proof.* Sei  $p \in \mathbb{P}_m$  mit  $||f - p||_{L^{\infty}(a,b)} = \min_{\tilde{p} \in \mathbb{P}_m} ||f - \tilde{p}||_{L^{\infty}(a,b)}$ 

$$|Qf - Q_n f| < |Qf - Qp| + |Q_n p - Qf| \le ||Q||||f - p||_{L^{\infty}(a,b)} + ||Q_n||||f - p||_{L^{\infty}(a,b)}$$

 $zz: (ii \implies i)$ 

Sei  $\epsilon > 0$ . Nach Weierstrass ex.  $m \in \mathbb{N}$  und  $p \in \mathbb{P}_m$  mit  $||f - p||_{L^{\infty}(a,b)} \leq \epsilon$ 

$$\Rightarrow |Qf - Q_n f| \leq \underbrace{|Qf - Qp|}_{\leq ||Q||} + \underbrace{|Qp - Q_n p|}_{\int 0 \text{ für } n \to \infty} + \underbrace{|Q_n p - Q_n f|}_{\leq ||Q_n||} \leq (||w||_{L^1(a,b)} + M)\epsilon + |Qp - Q_n p|$$

$$\leq \underbrace{||Q_n||}_{\leq M} \underbrace{||f - p||_{L^{\infty}(a,b)}}_{\leq \epsilon}$$

$$\Rightarrow \limsup_{n} |Qf - Q_n f| \leq (||w||_{L^1(a,b)} + M)\epsilon \forall \epsilon > 0$$

$$\Rightarrow 0 \leq \liminf_{n} |Qf - Q_n f| \leq \limsup_{n} |Qf - Q_n f| = 0$$

 $(i \implies ii)$  mittels **Satz von Banach-Steinhaus**:

X, Y Banach-Räume,  $T_n \in L(X, Y)$ 

Dann sind äquivalent:

- $\sup_{n\in\mathbb{N}}||T_n||_{L(X,Y)}<\infty$  glm. Beschränktheit
- $\forall x \in X : \sup_{n \in \mathbb{N}} ||T_n x||_Y < \infty$  p<br/>ktw. Beschränktheit

jetzt  $X \in \mathcal{C}[a,b], Y = \mathbb{K}, T_n = Q_n$ 

d.h.  $(Q_n f)_{n \in \mathbb{N}}$  konvergent nach (i), also punktweise Beschränktheit  $\implies \infty > \sup_n ||Q_n|| = \sup_n \sum_{j=0}^n |w_j^{(n)}|$ .

Bemerkung 36. 1. Die Implikation ( $i \implies ii$ ) ist nur mathematisch interessant. Der Satz von Banach-Steinhaus ist einer der Fundamentalsätze der Funktionalanalysis.

- 2. Die Implikation (ii  $\implies$  i) ist praktisch relevant. Die Eigenschaft  $\lim_n Q_n p = Qp \forall p \in \mathbb{P}$  gilt für alle interpolatorischen Quadraturformeln.
- 3. Die zentrale Bedingung  $\sup_n \sum_{j=0}^n |w_j^{(n)}| < \infty$  ist kritisch, aber für alle Gauss-Quadraturen erfüllt.  $\Longrightarrow$  Konvergenz gilt immer für Gauss-Quadratur.

### 4.2 Interpolatorische Quadraturformeln

Definition 11. Zu gegebenen Stützstellen  $a \le x_0 < ... < x_n \le b$  bezeichnet man  $Q_n f := \sum_{j=0}^n \underbrace{\left(\int_a^b L_j w dx\right)}_{Q(L_j)} f(x_j)$ 

als interpolatorische Quadraturformel (oder Interpolationsquadratur), wobei  $L_j x := \prod_{k=0}^n \frac{x - x_k}{x_j - x_k}$  die Lagrange-Polynome sind

**Satz 16.** Für  $Q_n f = \sum_{j=0}^n w_j f(x_j)$  sind äquivalent:

- $Q_n$  ist interpolatorisch
- Für  $f \in \mathcal{C}[a,b]$  mit Lagrange-Interpolationspolynom  $p \in \mathbb{P}_n$  (d.h.  $p(x_j) = f(x_j) \forall j = 0,...,n$ ) gilt  $Q_n f = Qp$
- $Exaktheitsgrad(Q_n) \ge n$ .

Proof. (i)  $\iff$  (ii).

Betrachte 
$$p = \sum_{j=0}^{n} f(x_j) L_j \implies Qp = \sum_{j=0}^{n} f(x_j) \int_a^b L_j w dx$$
 (i  $\implies$  iii) klar  $Q_n(L_j) = Q(L_j)$ , da  $L_j(x_k) = \delta_{jk}$   $\implies R = Q - Q_n$  ist Null auf Basis  $\{L_0, ..., L_n\} \implies R = 0$  auf  $\mathbb{P}_n \implies$  Exaktheit $(Q_n) \ge n$ . (iii  $\implies$  i)  $\checkmark$ 

Bemerkung 37. Die Gewichte einer Interpolationsquadratur kann man durch Lösen eines lin. GLS berechnen. Sei  $\{p_0,...,p_n\}\subseteq \mathbb{P}_n$  Basis, sei  $Q_nf:=\sum_{j=0}^n w_jf(x_j)$  eine Int.quadratur

$$\Longrightarrow \begin{pmatrix} p_0(x_0) & \dots & p_0(x_n) \\ \vdots & & \vdots \\ p_n(x_0) & \dots & p_n(x_n) \end{pmatrix} = \begin{pmatrix} w_0 \\ \vdots \\ w_n \end{pmatrix} = \begin{pmatrix} \int_a^b p_0 w dx \\ \vdots \\ \int_a^b p_n w dx \end{pmatrix}$$

Transponierte der Vandermonde-Matrix aus der Interpolation, also regulär

Beispiel 16. • abgeschlossene Newton-Cotes-Formeln  $x_j := a + j \frac{b-a}{n}$  für j = 0, ..., n

- affine Newton-Cotes-Formeln  $x_j := a + (j+1) \frac{b-a}{n+2}$  für j = 0, ..., n
- Moolavrin-Formeln  $x_j := a + (j + \frac{1}{2}) \frac{b-a}{n+1}$
- Clemshaus-Curtis-Formeln Verwende die Extrema oder die Nullstellen des Cebysev-Polynoms.

**Bemerkung 38.** Ein Satz von Kusmin besagt, dass für äquidistante Stützstellen immer gilt  $\sum_{j=0}^{n} |w_{j}^{(n)}| \to \infty$ , d.h. es gibt stetige Funktionen  $f \in \mathcal{C}[a,b]$  mit  $Q_{n}f \nrightarrow Qf$  für  $n \to \infty$ .

Bei Clemshaus-Curtis kann man 
$$w_j^{(n)} \ge 0$$
 zeigen, also  $\sum_{j=0}^n |w_j^{(n)}|^{\frac{1}{2}} \sum_{j=0}^n w_j^{(n)} = b-a$   $\implies$  Konvergenz  $Q_n f \to Q f \forall f \in \mathcal{C}[a,b]$ 

Bemerkung 39. Einige der abg. Newton-Cotes-Formeln haben auch eigene Namen.

- n = 1 Trapezregel,
- n = 2 Simpson-Regel,
- n = 3 Newton'sche  $\frac{3}{8}$ -Regel,
- n = 4 Milne-Regel

**Bemerkung 40.** Man verwendet die NC-Formeln in der Parix nur für  $n \le 8$ , da für  $n \ge 9$  negative Gewichte auftreten, was zur Auslöschung führt.

Bemerkung 41. Sei  $\tilde{Q}_n$  eine Quadratur auf [0,1] zu w=1. Sei  $Q_n^j$  die induzierte Quadratur auf  $[a_j,b_j]$  mit  $a=a_0 < b_0 = a_1 < b_1 = ... < b_n = b$ . Mit der Zerlegung

$$Qf = \int_{a}^{b} f dx = \sum_{j=0}^{N} \underbrace{\int_{a_{j}}^{b_{j}} f dx}_{=\approx Q_{p}^{j} f}$$

erhalte eine sogenannte summierte Quadraturformel  $Q_{nN}f := \sum_{j=0}^{N} Q_n^j f$ .

Falls  $Exaktheitsgrad(\tilde{Q}_n) \ge 0$  und  $\max_{j=0,...,N} (b_j^N - a_j^N) \to 0$ , so folgt  $Q_{nN}f \to Qf$  für  $N \to \infty, \forall f \in \mathcal{C}[a,b]$  und sie kriegen sogar a-priori Fehlerabschätzungen!

Satz 17. Sie Stützstellen seien symmetrisch, d.h.  $x_j = a + b - x_{n-j} \forall j = 0, ..., n$ . Das Gewicht sei symmetrisch, d.h.  $w(x) = w(a+b-x) \forall x \in [a,b]$ 

- 1. Die Gewichte der zugehörigen Interpolationsquad.  $Q_n$  sind symmetrisch, d.h.  $w_j = w_{n-j} \forall j = 0,...,n$
- 2. Falls n gerade, so gilt  $Exaktheit(Q_n) \ge n+1$

*Proof.* (i) Betrachte  $\tilde{Q}_n f := \sum_{j=0}^n w_{n-j} f(x_j)$ 

zz: Exaktheit $(\tilde{Q}_n) \ge n$  (dann  $\tilde{Q}_n$  interpolatorisch, d.h.  $\{w_j\}$  eindeutig durch  $\{x_j\}$ ) Betrachte  $p_k(x) := \left(x - \frac{a+b}{2}\right)^k$ ,  $\tilde{p}_k(x) := p_k(a+b-x) = \left(\frac{a+b}{2} - x\right)^k = (-1)^k p_k(x)$ 

$$\tilde{Q}_{n}p_{k} = \sum_{j=0}^{n} w_{n-j}p_{k}(x_{j}) = \sum_{l=0}^{n} w_{l} \underbrace{p_{k}(x_{l})}_{=a+b-x_{l}} = Q_{n}\tilde{p}_{k} = Q\tilde{p}_{k} \forall k = 0, ..., n$$

$$Q\tilde{p}_k = \int_a^b p_k(a+b-x) \underbrace{w(x)}_{=w(a+b-x)} dx = \int_a^b p_k(y)w(y)dy = Qp_k$$

 $\Longrightarrow \tilde{Q}_n p_k = Q p_k \forall k=0,...,n \implies \tilde{Q}_n \text{ interpolatorisch.}$  (ii) zz:  $Q_n p_{n+1} = Q p_{n+1} = 0, \ x_{\frac{1}{2}} = \frac{a+b}{2}$ 

$$Q_{n}p_{n+1} = \sum_{j=0}^{n} w_{j}p_{n+1}(x_{j}) = \sum_{j=1}^{\frac{n}{2}} w_{\frac{n}{2}-j}(x_{\frac{n}{2}-j} - \frac{a+b}{2})^{n+1} + \sum_{j=1}^{\frac{n}{2}} \underbrace{w_{\frac{n}{2}+j}}_{w_{\frac{n}{2}-j}} \underbrace{\left(x_{\frac{n}{2}+j} - \frac{a+b}{2}\right)^{n+1}}_{w_{\frac{n}{2}-j}} = 0$$

$$Qp_{n+1} = \int_{a}^{b} p_{n+1}wdx = -\int_{a}^{b} \underbrace{\tilde{p}_{n+1}(x)}_{p_{n+1}(a+b-x)} \underbrace{w(x)}_{p_{n+1}(a+b-x)} dx = -\int_{a}^{b} p_{n+1}(y)w(y)dy = -Qp_{n+1}$$

 $\implies Qp_{n+1} = 0$ 

**Korollar 3** (Konkrete Fehlerabschätzungen). Sei w(x) = 1,  $C_{\mathbb{K}} = 1$  für f reellwertig,  $C_{\mathbb{K}} = \sqrt{2}$  für f komplexwertig.

- 1. Die Trapezregel  $Q_1 f = \frac{b-a}{2} (f(a) + f(b))$  erfüllt  $|Qf Q_1 f| \le C_{\mathbb{K}} \frac{(b-a)^3}{12} ||f''||_{L^{\infty}(a,b)} \forall f \in \mathcal{C}^2[a,b]$
- 2. Die Simpson-Regel  $Q_2 f = \frac{b-a}{6} \left( f(a) + 2f\left(\frac{a+b}{2}\right) + f(b) \right)$  erfüllt  $|Qf Q_2 f| \le C_{\mathbb{K}} \frac{(b-a)^5}{2880} ||f^{(4)}||_{L^{\infty}(a,b)} \forall f \in \mathcal{C}^4[a,b]$

*Proof.*  $Q_1, Q_2$  sind abg. Newton-Cotens-Formeln, also interpolatorisch.

1. Sei  $p \in \mathbb{P}_1$  mit p(a) = f(a), p(b) = f(b)

$$\implies |Qf - Q_1 f| = |Qf - Qp| \le \int_a^b \underbrace{|f(x) - p(x)|}_{\le C_{\mathbb{K}} \frac{||f'||_{L^{\infty}(a,b)}}{2!} |x - a||x - b|} \le C_{\mathbb{K}} \frac{||f'||_{L^{\infty}(a,b)}}{2!} \underbrace{\int_a^b (x - a)(b - x) dx}_{= \frac{(b - a)^3}{6}}$$

2. Sei  $p \in \mathbb{P}_3$  mit  $p(a) = f(a), p(b) = f(b), p\left(\frac{a+b}{2}\right) = f\left(\frac{a+b}{2}\right)$  und  $p'\left(\frac{a+b}{2}\right) = f'\left(\frac{a+b}{2}\right)$ 

$$\implies |Qf - Q_2f| = |Qf - \underbrace{Q_2}_{=Qp}| = |Qf - Qp| \le \int_a^b |f(x) - p(x)| dx \le$$

$$C_{\mathbb{K}} \frac{||f^{(4)}||_{L^{\infty}(a,b)}}{4!} \underbrace{\int_{a}^{b} (x-a)(b-x) \left(\frac{a+b}{2} - x\right)^{2} dx}_{1}$$

Bemerkung 42. Auch mit Fehlerabschätzung aus Konvergenzsatz + Abschätzung des Bestapprox.fehlers durch Interpolationsfehler bekommt man konkrete Fehlerabschätzungen, allerdings schlechtere Konstanten - $\dot{c}$  Trapezregel  $\frac{1}{4}$  statt  $\frac{1}{12}$ .

### 4.3 Gauss-Quadratur

Ziel: Konstruiere (eindeutige) Quadraturformel  $Q_n$  mit Exaktheit $(Q_n) = 2n + 1$  klar:  $Q_n$  muss interpolatorisch sein.

Bemerkung 43. Die Analysis in diesem Abschnitt geht auch für ein unbeschränktes Intervall, z.B.  $(0, \infty), (-\infty, \infty)$  sofern  $\int_a^b |x|^n w(x) < \infty \forall n \in \mathbb{N}_0$ .

Betrachte Innenproduktraum  $H := \{f : (a,b) \to \mathbb{R} \text{ integrierbar } |||f|| < \infty\} \text{ mit } ||f|| = < f, f > \frac{1}{2}, < f, g > = \int_a^b fgw dx$ 

 $klar: \langle .,. \rangle$  Skalarprodukt  $(-\dot{c} L^2(a,b;wdx) = H)$ 

**Lemma 9** (Gram-Schmidt-Orthogonalisierung). Sei  $(x^n)_{n\in\mathbb{N}}$  die Folge der Monome in H. Definiere induktiv  $p_0 := x^0 = 1, p_n := x^n - \sum_{k=0}^{n-1} \frac{\langle x^n, p_k \rangle}{||p_n||^2} p_k$ 

 $\implies (p_n)_{n\in\mathbb{N}}$  sind orthogonal bzgl. <.,.> und insb.  $\{p_0,...,p_n\}\subseteq\mathbb{P}_n$  Basis und alle  $p_n$  haben Leitkoeffizient 1. Die Polynome  $p_n$  heißen **Orthogonalpolynome**.

Bemerkung 44. Für (a,b)=(-1,1), w=1 erhält man die **Legendre-Polynome**. Für  $(a,b)=(-1,1), w(x)=\frac{1}{\sqrt{1-x^2}}$  erhält man **Cebysev-Polynome**. Für  $(a,b)=(0,\infty)$  und  $w(x)=e^{-x}$  erhält man **Lagrange-Polynome**.

**Lemma 10.** Es seinen  $x_0, ..., x_n \in \mathbb{C}$  die gemäß Vielfachheit gezählten Nullstellen des Orth.pl.  $p_{n+1} \in \mathbb{P}_{n+1}$ 

- 1. alle Nullstellen sind einfach und liegen in (a, b)
- 2. Mit den Lagrange-Polynomen  $L_j(x) = \prod_{k=0}^n \frac{x-x_k}{x_j-x_k}$  gilt  $x_j = \frac{\langle xL_j, L_j \rangle}{||L_j||^2}$

*Proof.* 1. Seien  $x_0, ..., x_k \in (a, b)$  alle Nullstellen von  $p_{n+1}$ , die ungeraden Vielfachheit haben und in (a, b) liegen, bzw. k = -1, falls keine solchen existieren.

$$q(x) := \prod_{j=0}^{k} (x - x_j), q \in \mathbb{P}_{k+1}$$

 $\implies r := qp_{n+1} \neq 0$  hat nur Nst. gerade Vielfachheit in  $(a,b) \implies r \geq 0$  in (a,b) oder  $r \leq 0$  in (a,b)

Annahme:  $k < n \implies 0 = < q, p_{n+1} > = \int_a^b rw dx \implies rw = 0$  f.ü. Widerspruch zu  $r \neq 0 \neq w$  fast überall. Also k = n.

2. Polynomdivision  $p_{n+1} = (x - x_i)q$  mit  $q \in \mathbb{P}_n$ 

$$\implies \underbrace{\langle p_{n+1}, q \rangle}_{=0} = \langle xq, q \rangle - x_j \langle q, q \rangle \Longrightarrow x_j = \frac{\langle xq, q \rangle}{\langle q, q \rangle} \text{ und } q = \prod_{k=0, k \neq j}^n (x - x_k) = cL_j$$

Satz 18 (Existenz + Eindeutigkeit der Gauss-Quadratur). 1. Ex. eind Quadraturformel  $Q_n f = \sum_{j=0}^n w_j f(x_j)$  mit  $Exaktheitsgrad(Q_n) = 2n + 1$ 

- 2. Die Knoten sind die Nullstellen von Orth.pol.  $p_{n+1} \in \mathbb{P}_{n+1}$
- 3. Die Gewichte erfüllen  $w_j = \int_a^b w L_j dx = \int_a^b w L_j^2 dx > 0$

4. 
$$|Qf - Q_n f| \le C_{\mathbb{K}} \frac{||f^{(2n+2)|}|_{L^{\infty}(a,b)}}{(2n+2)!} \int_a^b w(x) \prod_{j=0}^n (x-w_j)^2 dx \forall f \in \mathcal{C}^{2n+2}(a,b)$$

*Proof.* 1. Existenz: Wähle Nullstellen  $x_0, ..., x_n$  von  $p_{n+1}$ , definiere  $w_j = \int_a^b w L_j dx$ 

 $\implies$  Exaktheitsgrad $(Q_n) \ge n$ 

Sei  $q \in \mathbb{P}_{2n+1}$ . zz:  $Q_n q = Qq$ 

Polynomdivision  $\implies q = p_{n+1}\alpha + \beta \text{ mit } \alpha, \beta \in \mathbb{P}_n$ 

$$Q_n q = Q_n \beta = Q\beta = \langle \beta, 1 \rangle + \underbrace{\langle p_{n+1}, \alpha \rangle}_{=0} = \langle \underbrace{\beta + \alpha p_{n+1}}_{=q}, 1 \rangle = Qq$$

2. Eindeutigkeit: Sei  $\tilde{Q}_n f = \sum_{j=0}^n \tilde{w}_j f(\tilde{x}_j)$  eine weitere Quadraturformel mit Exaktheit $(\tilde{Q}_n) = 2n + 1$  zz:  $\tilde{x}_j \in \{x_0, ..., x_n\} \forall j = 0, ..., n$  (dann folgt  $\{\tilde{x}_0, ..., \tilde{x}_n\} = \{x_0, ..., x_n\}$  und damit  $\tilde{Q}_n = Q_n$ )

Sei  $j \in \{0, ..., n\}$ .

$$q(x) := \left(\prod_{k=0}^{n} (x - x_n)\right) \left(\prod_{k=0, k \neq j}^{n} (x - \tilde{x}_k)\right) \in \mathbb{P}_{2n+1}$$

$$\implies 0 = Q_n q = Qq = \tilde{Q}_n q = \underbrace{\tilde{w}_j}_{\neq 0} q(\tilde{x}_j)$$

$$q(\tilde{x}_j) = \left(\prod_{k=0}^{n} (\tilde{x}_j - x_k)\right) \underbrace{\left(\prod_{k=0, k \neq j}^{n} (\tilde{x}_j - \tilde{x}_k)\right)}_{\neq 0}$$

$$\implies \tilde{x}_j \in \{x_0, ..., x_n\}.$$

3.  $w_j = \int_a^b w L_j^2 dx > 0$ 

$$w_j = \int_a^b L_j w dx = Q(L_j) = Q_n(L_j) = \sum_{k=0}^n w_k \underbrace{L_j(x_k)^2}_{-\delta} = Q_n(L_j^2) = Q(L_j^2) = \int_a^b L_j^2 w dx$$

4. zz. Fehlerabschätzung

Wähle  $q \in \mathbb{P}_{2n+1}$  mit  $\underbrace{q(x_j) = f(x_j)}_{\text{um interpolatorisch}}, \underbrace{q'(x_j) = f'(x_j)}_{\text{zusätzliche Freiheit für Verbesserung}}$   $\forall j = 0, ..., n$ 

$$\implies |f(x) - q(x)| \le C_{\mathbb{K}} \frac{||f^{(2n+2)|}|_{L^{\infty}(a,b)}}{(2n+2)!} \prod_{j=0}^{n} (x - x_j)^2$$

$$\implies |Qf - \underbrace{Q_n f}_{=Q_n q = Qq}| = |Q(f - q)| \le \int_a^b |f(x) - q(x)| w(x) dx$$

**Lemma 11** (3-Term-Rekursion). Die Orth.pol.  $(p_n)_{n \in \mathbb{N}_0}$  erfüllen  $p_0(x) = 1, p_1(x) = x - \beta_0, p_{n+1}(x) = (x - \beta_n)p_n(x) - \gamma_n^2 p_{n-1}(x) \forall n \geq 1$  mit reellen Koeff.  $\beta_n = \frac{\langle xp_n, p_n \rangle}{||p_n||^2}, \gamma_n = \frac{||p_n||}{||p_{n-1}||}$ 

*Proof.* durch Induktion nach n.

Ind.anf. n = 0, 1:

Erinnerung 
$$p_0(x) = x^0 = 1, p_n(x) = x^k - \sum_{j=0}^{k-1} \frac{\langle x^k, p_j \rangle}{||p_j||^2} p_j = x - \frac{\langle x^1, p_0 \rangle}{||p_0||^2} p_0 = x - \frac{\langle x, 1 \rangle}{||11||^2} 1$$
  
Def  $q_{n+1}(x) = (x - \beta_n) p_n(x) - \gamma_n^2 p_{n-1}(x) \in \mathbb{P}_{n+1}$ , Leitkoeff $(q_{n+1}) = 1$  =Leitkoeff $(q_{n-1}) \Rightarrow p_{n+1} - q_{n+1} \in \mathbb{P}_n, \langle p_{n+1}, q \rangle = 0 \forall q \in \mathbb{P}_n$   
zz:  $\langle q_{n+1}, q \rangle = 0 \forall q \in \mathbb{P}_n$  (dann  $\langle p_{n+1} - q_{n+1}, \underbrace{p_{n+1} - q_{n+1}}_{\in \mathbb{P}_n} \rangle = 0$  also  $p_{n+1} - q_{n+1} = 0$ )

zz:  $\langle q_{n+1}, p_j \rangle = 0 \forall j = 0, ..., n$ Sei  $j \in \{0, ..., n-2\}$ :

$$< q_{n+1}, p_j > = < p_n, \underbrace{(x - \beta_n)p_j}_{\in \mathbb{P}_{n-1}} > -\gamma_n^2 < p_{n-1}, \underbrace{p_j}_{\in \mathbb{P}_{n-2}} > = 0$$

Sei j = n - 1:

$$< q_{n+1}, p_{n-1}> = < p_1, xp_{n-1}> -\beta_n \underbrace{< p_n, p_{n-1}>}_{=0} - \underbrace{\gamma_n^2 < p_{n-1}, p_{n-1}>}_{=< p_n, p_n> \text{ Def}, \gamma_n} = < p_n, \underbrace{xp_{n-1} - p_n}_{\in \mathbb{P}_{n-1}}> = 0$$

Sei j = n:

$$< q_{n+1}, p_n > = < xp_n, p_n > -\underbrace{\beta_n < p_n, p_n >}_{=< xp_n, p_n > \text{ Def. } \beta_n} - \gamma_n^2 \underbrace{< p_{n-1}, p_n >}_{=0} = 0$$

Übung: Mit den Konstanten  $\gamma_n,\beta_n$  der 3-Term-Rekursion betrachte

$$A = \begin{pmatrix} \beta_0 & -\gamma_1 & 0 & \dots & 0 \\ -\gamma_1 & \beta_1 & \gamma_2 & \dots & 0 \\ \vdots & & & & \vdots \\ 0 & \dots & \dots & -\gamma_n & \beta_n \end{pmatrix} \in \mathbb{R}_{\text{sym}}^{(n+1)\times(n+1)} \qquad v^{(k)} = \begin{pmatrix} \tau_0 p_0(x_k) \\ \vdots \\ \tau_n p_n(x_k) \end{pmatrix} \in \mathbb{R}^{n+1}$$

mit  $x_0,...,x_n$  Nullstellen von  $p_{n+1},\tau_j=(-1)^j\left(\prod_{k=1}^j\gamma_n\right)^{-1}$ 

$$\implies Av^{(k)} = x_k v^{(k)}$$
, d.h. die  $x_n$  sind genau die  $w_k := \int_a^b L_j w dx = \frac{||w||_{L^1(a,b)}}{||v^{(k)}|_2^2}$ 

DH: Um eine Gauss-Quadratur zu berechnen, muss man alle EW und alle EV der Matix A bestimmen (d.h. das EW-Problem vollständig lösen).

## 5 Iterative Lösung von GLS

Ziel:

- Wenn man nichtlineare GLS lösen will, so muss regelmäßig eine Folge von linearen GLS lösen (z.B. Newton).
- Man kann lineare GLS lösen, indem man iterativ Matrix-Vektor-Produkte ausrechnet, insb. muss man die Matrix nicht speichern (z.B. FFT, dividierte Diff.)

### 5.1 Fixpunktprobleme

**Definition 12.** Ein Iterationsverfahren ist ein Tripel  $(X, \Phi, x*)$  mit X metrischer Raum,  $\Phi: X \to X$ ,  $\Phi(x*) = x*$ , d.h. x\* ist ein Fixpunkt von  $\Phi$ . Zu einem Startwert  $x_0 \in X$ , sei  $x_{k+1} := \Phi(x_k) \forall x \in \mathbb{N}_0$  die erzeugte Iteriertenfolge  $(x_n)_{n \in \mathbb{N}_0}$ .

**Bemerkung 45.** 1. Existiert  $x := \lim_{n \to \infty} x_n$  und ist  $\Phi$  stetig bei x, so ist  $x = \Phi(x)$ , dann  $x = \lim_n x_{n+1} = \lim_n \Phi(x_n) = \Phi(x)$ .

2. Ist X normiert und die Lösung von F(x\*) = 0 gesucht mit  $F: X \to X$ , so formuliert man dies i.d.R. als Fixpunktproblem, z.B.  $x* = \Phi(x*) := x* \pm F(x*)$ .

Satz 19 (Banachscher Fixpunktsatz). X vollständig metrischer Raum, 0 < q < 1 und  $\Phi: X \to X$  mit  $d(\Phi(x), \Phi(y)) \leq qd(x, y)$   $\Longrightarrow$ 

- 1. Ex. eind.  $x* \in X$  mit  $\Phi(x*) = x*$
- 2. Für alle  $x_0 \in X$  und  $x_{k+1} := \Phi(x_k) \forall k \in \mathbb{N}_0$  gilt  $\lim_n x_k = x*$
- 3. Für alle  $k \in \mathbb{N}_0$  gilt:
  - $d(x_k, x*) \leq qd(x_{k-1}, x*)$
  - $d(x_k, x^*) \le \frac{q}{1-q} d(x_k, x_{k-1}) \le \frac{q^k}{1-q} d(x_1, x_0)$
  - $d(x_k, x_{k-1}) \le (1+q)d(x_{k-1}, x^*)$

Proof. 1. Eindeutigkeit Fixpunkt: Seien  $x*, y* \in X$  mit  $\Phi(x*) = x*, \Phi(y*) = y*$  $\implies d(x*, y*) = d(\Phi(x*), \Phi(y*)) \le qd(x*, y*) \implies d(x*, y*) = 0 \implies x* = y*$ 

- 2. gezeigt: Falls  $(x_k)_{k\in\mathbb{N}}$  konvergiert, ist  $x*=\lim_n x_k$  ein Fixpunkt.
- 3. zz:  $(x_k)_{k\in\mathbb{N}}$  für alle Startwerte  $x_0\in X$  eine Cauchy-Folge ist. Für  $m\leq n$  gilt

$$d(x_m, x_n) \leq \sum_{k=m}^{n-1} \underbrace{\frac{d(x_{k-1}), \Phi(x_k)) \leq q d(x_{n-1, x_k}) \leq q^{k-1} d(x_0, x_1)}{d(x_k, x_{k+1})}}_{\leq q^k d(x_0, x_1)} \leq \left(\sum_{k=m}^{n-1} q^k\right) d(x_0, x_1) \leq q^m \frac{1}{1-q} d(x_0, x_1) \to 0, m \to \infty.$$

4. Abschätzungen:

$$d(x_k, x^*) = d(\Phi(x_{k-1}), \Phi(x^*)) \le q \underbrace{d(x_{k-1}, x^*)}_{\le d(x_{k-1}, x_k) + d(x_k + x^*)}$$

$$\implies d(x_k, x^*)(1 - q) \le q \underbrace{d(x_{n-1}, x_n)}_{\le q^{k-1}d(x_0, x_1)} \le q^k d(x_0, x_1)$$

und 
$$d(x_k, x_{k-1}) \le \underbrace{d(x_k, x_*)}_{qd(x_{n-1}, x_*)} + d(x_{k-1}, x_*) \le (1+q)d(x_{k-1}, x_*)$$

**Definition 13.** Ein Iterationsverfahren  $(X, \Phi, x*)$  heißt

• global konvergent, gdw.  $\forall x_0 \in X : x* = \lim_{n \to \infty} x_n \ mit \ (x_n)_{n \in \mathbb{N}_0} \ der \ Iteriertenfolge \ x_{n+1} := \Phi(x_n) \forall n$ 

• lokal konvergent, gdw.  $\exists \epsilon > 0 \forall x_0 \in \underbrace{U_{\epsilon}(x*)}_{:=\{y \in X \mid d(x,y) < \epsilon\}} : x* = \lim_n x_n$ 

- linear konvergent (oder: mit Konvergenzordnung p=1), gdw.  $\exists q \in (0,1) \exists \epsilon > 0 \forall x_0 \in U_{\epsilon}(x*) \forall n \in \mathbb{N}_0 : d(x*,x_{n+1}) \leq qd(x*,x_n)$
- von Konvergenzordnung p > 1, gdw.  $\exists C > 0 \forall \epsilon > 0 \forall x_0 \in U_{\epsilon}(x*) \forall n \in \mathbb{N}_0 : d(x*, x_{n+1}) \leq Cd(x*, x_n)^p$ Die Menge  $U_{\epsilon}(x*)$  nennt man auch Konvergenzbereich.

**Beispiel 17.** Ist  $\Phi: X \to X$  eine (strikte) Kontraktion auf einem vollständig metrischen Raum mit Fixpunkt  $x* \in X$ , so ist  $(X, \Phi, x*)$  global linear konv.

**Lemma 12.** Sei  $(X, \Phi, x*)$  ein Iterationsverfahren mit Konvergenzordnung  $p \ge 1$ . Dann ist  $(X, \Phi, x*)$  lokal konvergent und in jeder Konvergenzordnung  $1 \le \tilde{p} \le p$ .

*Proof.* •  $p = 1 \implies \text{lokale konvergenz}$ 

Wähle 0 < q < 1 und  $\epsilon > 0$  gemäß Definition. Sei  $x_0 \in U_{\epsilon}(x*)$ . Dann  $d(x*, x_n) \leq q^k \underbrace{d(x*, x_0)}_{\in \mathbb{R}}$ 

• Konvergenzordnung  $p>1 \Longrightarrow$  lineare konvergenz mit  $q=\frac{1}{2}$ . Seien  $C>0, \epsilon>0$  gemäß Def. gewählt. Wähle  $\delta:=\min\{\epsilon,\left(\frac{1}{2C}\right)^{1/(p-1)}\}$ . Sei  $x_0\in U_\delta(x*)$ 

Beh. 
$$d(x_n, x*) \leq \underbrace{2^{-n}}_{\leq 1} \underbrace{d(x_0, x*)}_{<\delta} < \delta \forall n \in \mathbb{N}_0 \text{ (und } d(x_n, x*) \leq C \underbrace{d(x_{n-1}, x*)^{p-1}}_{\leq \delta^{p-1} \leq 1/(2C)} d(x_{n-1}, x*) \leq \frac{1}{2} d(x_{n-1}, x*) \forall n \in \mathbb{N}_0$$

Beweis der Beh. durch Induktion, klar n=0

TODO1321:31